Estudio de casos

Segmentación de lesiones en retinopatía diabética: U-Net frente a Segment Anything

MDS221 — Inteligencia Artificial • Unidad 2
Magíster en Data Science — Universidad Católica del Maule
Sergio Hernández, PhD • shernandez@ucm.cl

Modalidad	Individual.
Plazo	3/11/26
Dedicación	Aproximadamente 12 horas de trabajo autónomo, más el tiempo de GPU en Google Colab.
Entregables	Notebook reproducible `.ipynb` + informe en PDF (máximo 6 páginas).
Evaluación	Rúbrica de la sección **??** (240 puntos, 60 % de exigencia).

El caso en una frase. Segment Anything (SAM) aprendió de 1,1 mil millones de máscaras; IDRiD ofrece **54 imágenes** de entrenamiento y un microaneurisma ocupa **unos pocos pixeles**. ¿Le gana un U-Net entrenado con tan pocos datos a un modelo fundacional que recibe prompts perfectos? Y si pierde, **¿cuánto cuesta en clics de un oftalmólogo cerrar la brecha?**

1. Contexto clínico

La retinopatía diabética (RD) afecta aproximadamente al 22 % de las personas con diabetes y es una de las principales causas de ceguera prevenible en adultos en edad laboral (Teo et al., 2021). Su detección temprana depende de reconocer en una fotografía de fondo de ojo lesiones pequeñas y dispersas: microaneurismas, hemorragias y exudados. Un programa de screening poblacional necesita revisar miles de imágenes, y la segmentación automática de esas lesiones es la base para graduar la enfermedad y decidir a quién derivar.

En la clase 2.6 vimos dos caminos: entrenar un modelo especializado (U-Net con *transfer learning*) o usar un modelo fundacional que segmenta cualquier objeto a partir de un prompt (SAM). Esta tarea los compara sobre el mismo problema clínico, con el notebook:

`labs/2.6.2_SegmentacionRetinopatiaSAM.ipynb`

2. El conjunto de datos

Indian Diabetic Retinopathy Image Dataset (IDRiD) — parte *A. Segmentation*. Porwal et al. (2018), *Data* 3(3):25.
https://ieee-dataport.org/open-access/indian-diabetic-retinopathy-image-dataset-idrid

81 fotografías de fondo de ojo de 4288×2848 pixeles, divididas en 54 de entrenamiento y 27 de prueba, con una máscara binaria por lesión:

Lesión	Código	Imágenes con máscara	Descripción
Microaneurismas	`MA`	81	Dilataciones capilares; el primer signo de RD. Miden pocos pixeles.
Hemorragias	`HE`	80	Sangrado intrarretiniano: manchas rojas puntiformes o en llama.
Exudados duros	`EX`	81	Depósitos de lípidos amarillos, de bordes nítidos.
Exudados blandos	`SE`	40	Manchas algodonosas por isquemia; blanquecinas y difusas.
Disco óptico	`OD`	81	Estructura anatómica, no lesión; útil como control.

Si una imagen no tiene máscara para una lesión, esa lesión está ausente. El archivo `A. Segmentation.zip` se descarga desde IEEE Dataport con una cuenta gratuita y se deja en `data/` o en Google Drive. La lesión se elige en la celda de parámetros:

```
LESION = 'EX'              # 'MA', 'HE', 'EX', 'SE' u 'OD'
IMG_H, IMG_W = 704, 1056 # múltiplos de 32
DATA_ZIP = 'data/A. Segmentation.zip'
```

3. Línea base

Ejecute el notebook completo con `LESION = 'EX'` y la configuración por defecto. Esta tabla, con métricas sobre las 27 imágenes de **prueba**, es la línea base de todo el informe:

Método	Dice	IoU	Dice por imagen	AUPR
U-Net ResNet-34, BCE				
U-Net ResNet-34, Dice + Focal				
SAM ViT-B, caja				—
SAM ViT-B, 1 clic				—
SAM ViT-B, 3 clics				—
SAM ViT-B, 5 clics				—

SAM no entrega probabilidades calibradas por pixel, por eso no se le calcula AUPR, que es la métrica oficial del desafío IDRiD. Los prompts de SAM se simulan desde el *ground truth*: son un **oráculo**, no lo que haría un clínico real. Esa asimetría es parte de lo que debe analizar.

Pregunta central del caso. Para un programa de screening de RD, ¿conviene (a) entrenar un *modelo especializado* pequeño con pocas imágenes anotadas, (b) usar un *modelo fundacional* con prompts de un oftalmólogo, o (c) usar el modelo fundacional como *herramienta de anotación* para entrenar el especializado? Su informe debe defender una respuesta **con evidencia propia**, no con citas.

4. Tareas

Cada tarea se conecta con una parte de la clase 2.6. Las métricas se reportan siempre en **prueba**; la validación (6 imágenes de entrenamiento reservadas) solo sirve para elegir umbrales o épocas. La comparación BCE frente a Dice + Focal se reporta con **al menos 3 semillas** y media ± desviación estándar; el resto puede usar una semilla, declarándolo.

T1 — Línea base y desbalance

1. Complete la tabla de la línea base y adjunte las curvas de entrenamiento (pérdida, Dice y AUPR de validación) de ambos U-Net.

2. Reporte la fracción de pixeles de lesión y la exactitud de pixel de un modelo que predice "fondo" en todo. Explique por qué esa métrica no sirve aquí.
3. Presente una figura cualitativa con al menos dos imágenes de prueba, marcando verdaderos positivos, falsos positivos y falsos negativos para el mejor U-Net y el mejor SAM.

T2 — Umbral y AUPR

1. Busque en validación el umbral que maximiza el Dice de cada U-Net (entre 0,05 y 0,95, paso 0,05) y aplíquelo en prueba. Reporte el Dice antes y después.
2. Explique por qué el umbral 0,5 perjudica al modelo entrenado con BCE, relacionando desbalance, calibración de las probabilidades y umbral óptimo.
3. ¿Por qué el AUPR no cambia al mover el umbral? ¿Qué métrica usaría para elegir entre los dos U-Net y por qué?

T3 — Transfer learning

1. Compare tres configuraciones con Dice + Focal: encoder pre-entrenado y ajustado (base), pre-entrenado y congelado (`freeze_encoder=True`) y sin pre-entrenar (`PRETRAINED = False`).
2. Reporte para cada una los parámetros entrenables, el tiempo por época y las métricas de prueba.
3. Contraste con el laboratorio 2.5: ¿el congelamiento del encoder se comporta igual en clasificación de mascotas que en segmentación de fondo de ojo? Proponga una explicación.

T4 — Otras lesiones y resolución

1. Repita la línea base con `LESION = 'MA'` y `LESION = 'SE'`. Ordene las cuatro lesiones por dificultad según sus resultados.
2. Para microaneurismas, compare la resolución por defecto (704×1056) con `IMG_H, IMG_W = 1408, 2112`.
3. Cuantifique cuántas componentes conexas de MA se pierden al reducir la imagen de 4288×2848 a la resolución de trabajo, y discuta el compromiso entre resolución, memoria de GPU y contexto.

T5 — Comparación con SAM

1. Grafique el Dice de SAM contra el número de clics (1, 3 y 5), con el Dice del mejor U-Net como línea de referencia. ¿Cuántos clics necesita SAM para igualarlo?
2. Analice al menos dos sesgos del protocolo: los prompts provienen del *ground truth* y solo se marcan las `MAX_COMPONENTS` lesiones más grandes. Mida el efecto del segundo variando `MAX_COMPONENTS`.
3. Estime el costo humano: clics por imagen que necesitaría un oftalmólogo para igualar al U-Net, frente al costo de anotar las 54 imágenes de entrenamiento.

T6 — Preprocesamiento y adaptación al dominio

1. Evalúe SAM con caja y con 3 clics sobre la imagen original y sobre la imagen con CLAHE. Reporte las cuatro combinaciones.
2. Explique el resultado considerando con qué datos fue entrenado SAM y qué hace CLAHE al histograma local.
3. **Opcional (bonificación):** repita con MedSAM (`RUN_MEDSAM = True`) y discuta si el ajuste al dominio médico compensa que su entrenamiento casi no incluya fondo de ojo.

5. Entregables

1. **Notebook reproducible** (`.ipynb`), ejecutado y con todas las salidas visibles. Toda cifra del informe debe aparecer en una salida del notebook. Un cuaderno que no corre se evalúa como si no se hubiera entregado.
2. **Informe** en PDF, máximo 6 páginas sin contar referencias ni anexos, con esta estructura mínima:
   - Métodos: preprocesamiento, arquitectura, pérdidas, métricas, protocolo de prompts y todo parámetro que haya cambiado respecto del notebook.
   - Línea base completa (T1).
   - Resultados de T2–T6, cada uno con su tabla o figura y su lectura.
   - Su respuesta a la pregunta central: (a), (b) o (c) — **y por qué descarta las otras dos**.
   - Una sección final de **límites**: qué no logró establecer y qué experimento habría hecho falta.
3. **Nombre de archivos:** `T2.6_<apellido>_<nombre>.ipynb` y `.pdf`.

Sobre el uso de asistentes de IA. Está permitido y se espera que lo declaren: incluyan un párrafo indicando qué herramienta usaron y para qué. Lo que se evalúa es el criterio con que interpretan los resultados, y eso no se delega. Un informe con conclusiones que el propio cuaderno no respalda se penaliza en *Análisis de datos y evidencia*, independientemente de quién lo haya escrito.

Ganar en la tabla no es el resultado. SAM recibe prompts de oráculo y el U-Net se entrena con 48 imágenes: cualquiera de los dos puede ganar por razones que no sobreviven a una clínica real. Lo que se evalúa es que identifiquen **bajo qué protocolo** gana cada uno y si ese protocolo es realista para un programa de screening.

6. Rúbrica de evaluación

Seis criterios, cuatro niveles. Puntaje máximo **240 puntos**. La tarea opcional de MedSAM suma hasta 10 puntos de bonificación, con tope en 240.

Aspecto	Excelente (40)	Bueno (30)	Aceptable (20)	Bajo (10)
Reproducción y rigor experimental	El cuaderno corre completo; línea base completa en prueba; umbrales elegidos en validación; semillas múltiples donde se piden; cambios de parámetros declarados.	Línea base completa con protocolo correcto; la repetición con semillas o la declaración de cambios es parcial.	Resultados con protocolo discutible: umbral elegido en prueba, métricas de validación reportadas como finales o una sola semilla en T1.	El cuaderno no corre o las cifras del informe no son verificables.
Umbral, métricas y desbalance (T1–T2)	Explica con evidencia la relación entre desbalance, calibración, umbral y AUPR; elige la métrica de comparación con criterio.	Experimento de umbral correcto; explicación incompleta de por qué falla BCE o de por qué el AUPR no depende del umbral.	Reporta las métricas sin explicar su comportamiento, o explica sin experimento.	Usa exactitud de pixel como evidencia o interpreta las métricas de forma errónea.
Transfer learning y resolución (T3–T4)	Tres configuraciones con parámetros, tiempo y métricas; tres lesiones evaluadas; cuantifica los MA perdidos y discute el compromiso de resolución.	Experimentos completos con una omisión (tiempo, una lesión o la cuantificación de MA perdidos).	Solo dos configuraciones o una lesión adicional, sin análisis de resolución.	Experimentos ausentes o conclusiones no respaldadas por ellos.
Evaluación crítica de SAM (T5–T6)	Curva de Dice contra clics con referencia; mide el efecto de `MAX_COMPONENTS`; estima el costo humano; explica el efecto de CLAHE desde el dominio de entrenamiento.	Curva y análisis de sesgos correctos, sin experimento sobre `MAX_COMPONENTS` o sin estimación de costo.	Reporta cifras de SAM sin discutir la validez de la comparación con el U-Net.	Concluye que un método "es mejor" sin considerar el oráculo, o con conclusiones contrarias a sus propios datos.
Análisis de datos y evidencia	Figuras legibles y bien elegidas (curvas, mapas de error, ampliaciones), incertidumbre reportada, cada afirmación rastreable al cuaderno.	Análisis sólido; las figuras comunican, con mejoras posibles en claridad o en el tratamiento de la incertidumbre.	Análisis adecuado pero superficial; faltan figuras cualitativas o comparaciones por lesión.	Análisis inconsistente con las cifras del cuaderno.
Comunicación y recomendación clínica	Informe preciso dentro de 6 páginas; responde la pregunta central descartando con evidencia las otras dos opciones y reconoce sus límites.	Bien organizado y con recomendación fundada, con errores menores o límites tratados con poca profundidad.	Se entiende, pero la recomendación es genérica o excede la extensión.	Desorganizado, sin recomendación o con errores graves que impiden la comprensión.

Conversión a nota (60 % de exigencia, P = puntaje sobre 240):

$$\text{Nota} = \begin{cases} 1{,}0 + 3{,}0\,\dfrac{P}{144} & \text{si } P < 144, \\ 4{,}0 + 3{,}0\,\dfrac{P - 144}{96} & \text{si } P \geq 144. \end{cases}$$

Puntaje	48	96	120	**144**	168	192	216	**240**
Nota	2,0	3,0	3,5	**4,0**	4,75	5,5	6,25	**7,0**

Descuentos: **[_ _ décimas]** por día de atraso.

7. Referencias

- Porwal, P., Pachade, S., Kamble, R., Kokare, M., Deshmukh, G., Sahasrabuddhe, V. & Meriaudeau, F. (2018). *Indian Diabetic Retinopathy Image Dataset (IDRiD): A Database for Diabetic Retinopathy Screening Research*. Data, 3(3), 25. https://doi.org/10.3390/data3030025
- Teo, Z. L. et al. (2021). *Global Prevalence of Diabetic Retinopathy and Projection of Burden through 2045*. Ophthalmology, 128(11), 1580–1591. https://doi.org/10.1016/j.ophtha.2021.04.027
- Ronneberger, O., Fischer, P. & Brox, T. (2015). *U-Net: Convolutional Networks for Biomedical Image Segmentation*. MICCAI.
- He, K., Zhang, X., Ren, S. & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. CVPR.
- Lin, T.-Y., Goyal, P., Girshick, R., He, K. & Dollár, P. (2017). *Focal Loss for Dense Object Detection*. ICCV.
- Milletari, F., Navab, N. & Ahmadi, S.-A. (2016). *V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation*. 3DV.
- Kirillov, A. et al. (2023). *Segment Anything*. ICCV.
- Ravi, N. et al. (2025). *SAM 2: Segment Anything in Images and Videos*. ICLR.
- Ma, J., He, Y., Li, F., Han, L., You, C. & Wang, B. (2024). *Segment Anything in Medical Images*. Nature Communications, 15, 654. https://doi.org/10.1038/s41467-024-44824-z

---

Material del curso MDS221, Magíster en Data Science, Universidad Católica del Maule. El conjunto IDRiD se distribuye a través de IEEE Dataport; revise sus condiciones de uso antes de redistribuir imágenes.