

Sistemas Expertos

El paradigma simbólico de la IA

Sergio Hernández, PhD
shernandez@ucm.cl



Magíster en Data Science — Universidad Católica del Maule

1. ¿Qué es un sistema experto?
2. Representar el conocimiento: lógica proposicional
3. Inferir: el motor de reglas
4. Incertidumbre: modelos gráficos probabilísticos
5. Historia, límites y legado
6. Cierre y lecturas

Objetivo de la clase

Entender el **paradigma simbólico** en concreto: cómo se escribe una base de conocimiento, cómo un motor de inferencia encadena reglas, y por qué este enfoque triunfó y después se estancó. Al final, la respuesta formal a su punto débil: representar el conocimiento incierto con una **red bayesiana**.


Sistemas expertos

Programas que resuelven problemas de un **dominio acotado** emulando el razonamiento de un especialista humano, a partir de conocimiento **declarado explícitamente** y no aprendido de los datos.

Sistemas expertos

Programas que resuelven problemas de un **dominio acotado** emulando el razonamiento de un especialista humano, a partir de conocimiento **declarado explícitamente** y no aprendido de los datos.

- ▶ Fueron el primer éxito **comercial** de la IA (década de 1980).
- ▶ El conocimiento se escribe, se lee y se audita: cada conclusión tiene una traza.
- ▶ Contraste con la clase anterior: aquí el programador **escribe la regla**; en aprendizaje automático escribe el **objetivo** y la regla se ajusta sola.
- ▶ Ambos enfoques conviven hoy en sistemas híbridos.



SABIDURÍA

saber *cuándo* aplicar el conocimiento
decidir no tratar y derivar

CONOCIMIENTO

reglas y relaciones entre hechos
SI fiebre Y tos ENTONCES viral

INFORMACIÓN


el dato interpretado en contexto
38,5°C = fiebre

DATOS

hechos crudos, sin interpretar
temperatura = 38,5

Idea clave: Un sistema experto vive en el tercer nivel: su valor no está en almacenar datos, sino en codificar las **reglas** que un especialista aplica sobre ellos.

Anatomía de un sistema experto



Idea clave: La separación entre **conocimiento** (las reglas, que cambian) y **control** (el motor, que no cambia) es lo que permite reutilizar un mismo motor en dominios distintos: es la arquitectura de un *shell*.

Cuatro características que los definen

Heurísticos

Codifican *reglas de buena práctica* del especialista, no un modelo matemático cerrado del dominio.

Explicables

Pueden reconstruir la cadena de reglas que llevó a la conclusión. Hoy lo llamamos **XAI**.

Conocimiento separado del control

La base de reglas se edita sin tocar el motor. Permite que el *experto* colabore sin programar.

Toleran incertidumbre

Trabajan con información incompleta mediante **factores de certeza** o probabilidades.

A cambio, el dominio debe ser **estrecho y estable**: nada de sentido común ni de conocimiento general.

- ▶ Una **proposición** es un enunciado sobre el mundo que solo puede ser verdadero o falso.
- ▶ Se abrevian con símbolos: P , Q , R .
- ▶ Las **conectivas** combinan proposiciones para expresar afirmaciones compuestas.

Ejemplo del dominio médico:

P : el paciente tiene fiebre Q : el paciente tiene tos seca

$P \wedge Q \rightarrow R$: si tiene fiebre y tos seca, hay infección viral.

$\neg$	negación	no
$\wedge$	conjunción	y
$\vee$	disyunción	o
$\oplus$	disyunción excl.	o bien
$\rightarrow$	implicación	si... entonces
$\leftrightarrow$	bicondicional	si y solo si

Las seis conectivas en una sola tabla

P	Q	$\neg P$	$P \wedge Q$	$P \vee Q$	$P \oplus Q$	$P \rightarrow Q$	$P \leftrightarrow Q$
F	F	V	F	F	F	V	V
F	V	V	F	V	V	V	F
V	F	F	F	V	V	F	F
V	V	F	V	V	F	V	V


antecedente falso
 $\Rightarrow$ *trivialmente verdadera*

Idea clave: $P \rightarrow Q$ **no** afirma causalidad: solo excluye el caso P verdadero con Q falso. *Si la luna es de queso, apruebo el ramo* es una proposición verdadera.

- ▶ Una **base de conocimiento** (KB) es el conjunto de sentencias que el agente da por ciertas.
- ▶ Un **modelo** es una asignación de verdadero/falso a *todas* las proposiciones: una forma posible del mundo.
- ▶ Con n proposiciones hay 2^n modelos.

$KB \models \alpha$ si α es verdadera en *todo* modelo donde KB lo es.


Idea clave: Comprobar la consecuencia enumerando modelos (*model checking*) es correcto pero inviable: por eso los sistemas expertos no enumeran mundos, sino que **aplican reglas**.



Implicación ($\rightarrow$) vs. consecuencia lógica ($\models$)

- ▶ $\rightarrow$ es una **conectiva**: construye una nueva proposición, que puede ser verdadera o falsa.
- ▶ $\models$ es una **relación** entre conjuntos de sentencias: se cumple o no se cumple, y se verifica sobre *todos* los modelos.

Si α : *es martes de enero* y β : *es enero*, entonces $\alpha \models \beta$: no existe ningún mundo donde lo primero valga y lo segundo no.



Idea clave: $\alpha \models \beta$ significa que el conjunto de mundos donde α es verdadera está **contenido** en aquel donde β lo es.

La regla que ejecuta el motor: *modus ponens*

$\alpha \rightarrow \beta$	premisas
α	
β	conclusión

Si sabemos que *si llueve, Harry está dentro* y además *llueve*, podemos afirmar *Harry está dentro*.

Otras reglas de inferencia útiles

Regla	De... se deduce
Eliminación de $\wedge$	$\alpha \wedge \beta \Rightarrow \alpha$
Doble negación	$\neg(\neg\alpha) \Rightarrow \alpha$
Eliminación de $\rightarrow$	$\alpha \rightarrow \beta \Rightarrow \neg\alpha \vee \beta$
De Morgan	$\neg(\alpha \wedge \beta) \Rightarrow \neg\alpha \vee \neg\beta$
Resolución	$\alpha \vee \beta, \neg\beta \vee \gamma \Rightarrow \alpha \vee \gamma$

Idea clave: Aplicar reglas de inferencia genera conclusiones **sin enumerar los 2^n modelos**. Es la diferencia entre demostrar y verificar por fuerza bruta.

En un sistema experto el conocimiento no se escribe como fórmulas sueltas, sino como **reglas de producción** sobre una memoria de hechos:

R1

SI fiebre **Y** tos seca
ENTONCES infección viral

R2

SI infección viral **Y** dolor muscular
ENTONCES gripe


R3

SI fiebre **Y** manchas cutáneas
ENTONCES infección bacteriana

Hechos observados en el caso:
fiebre, tos seca, dolor muscular.


- ▶ Cada regla es *modus ponens* disfrazado: antecedente → consecuente.
- ▶ El motor decide **en qué orden** probarlas. Hay dos estrategias, y esa elección lo cambia todo.

Encadenamiento hacia adelante (*forward chaining*)



- ▶ Parte de los **hechos** y dispara toda regla cuyo antecedente se satisfaga, añadiendo el consecuente a la memoria de trabajo. Repite hasta que no haya reglas nuevas que disparar.
- ▶ Conviene cuando hay **pocos datos y muchas conclusiones posibles**: monitoreo, alarmas, configuración.

Encadenamiento hacia atrás (*backward chaining*)



- ▶ Parte de una **hipótesis** y busca reglas que la concluyan; sus antecedentes se vuelven nuevas submetas, hasta topar con hechos conocidos o preguntarle al usuario.
- ▶ Conviene cuando hay **pocas hipótesis y muchos datos posibles**: diagnóstico médico o de fallas. Es lo que hacía MYCIN.

¿Cuál de las dos estrategias?

	Hacia adelante	Hacia atrás
Dirigido por	los datos	la meta
Punto de partida	hechos observados	hipótesis
Pregunta al usuario	rara vez	solo lo que necesita
Bueno cuando	pocos datos, muchas conclusiones	muchos datos, pocas hipótesis
Riesgo típico	derivar hechos inútiles	explorar ramas que fracasan
Ejemplo	configuración (XCON)	diagnóstico (MYCIN)

- ▶ Ambas usan **la misma base de reglas**: cambia solo la estrategia de control del motor.
- ▶ Es exactamente la separación conocimiento/control de la que hablamos al principio.

Razonar con incertidumbre: factores de certeza

El conocimiento clínico rara vez es categórico. MYCIN asociaba a cada regla un **factor de certeza** $CF \in [-1, 1]$.

R1 con certeza

SI fiebre Y tos seca

ENTONCES infección viral ($CF = 0,7$)

$$CF(\text{concl.}) = \min_i CF(\text{premisa}_i) \times CF(\text{regla})$$

$$CF_{1,2} = CF_1 + CF_2 (1 - CF_1) \quad (CF_i > 0)$$

Idea clave: Los factores de certeza fueron una solución *de ingeniería*, no probabilística: no satisfacen los axiomas de Kolmogorov. Las **redes bayesianas**, que vemos a continuación, son la respuesta formal al mismo problema.

Traza del caso:

1. $CF(\text{fiebre}) = 1,0$, $CF(\text{tos seca}) = 0,8$
2. premisa: $\min(1,0; 0,8) = 0,8$
3. R1: $0,8 \times 0,7 = 0,56$
4. otra regla aporta 0,4 a la misma conclusión
5. combinadas:
 $0,56 + 0,4(1 - 0,56) = 0,736$

Lo que falla en los CF

- ▶ No hay una semántica: $CF = 0,7$ no es un número comprobable contra el mundo.
- ▶ La combinación supone evidencia **independiente**: si dos reglas leen el mismo síntoma, se cuenta dos veces.
- ▶ El razonamiento no se puede invertir: de $CF(\text{síntoma} \rightarrow \text{enfermedad})$ no se recupera el sentido contrario.

La alternativa formal

Modelar el dominio con una **distribución conjunta**. Con E la enfermedad y S los síntomas, toda pregunta es marginalizar y condicionar:

$$P(E | S) = \frac{P(E, S)}{P(S)}$$

Regla de la cadena:


$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i | X_{<i})$$

$$\text{con } X_{<i} = \{X_1, \dots, X_{i-1}\}$$

Idea clave: Correcto pero inviable: la conjunta sobre n variables binarias necesita $2^n - 1$ números; con $n = 30$ son mil millones que nadie puede estimar ni almacenar. Hace falta **estructura**.


Idea

Usar un **grafo** para declarar qué variables interactúan *directamente*. Los nodos son variables aleatorias; la ausencia de una arista es una afirmación de **independencia condicional**. El grafo hace dos cosas a la vez: **factoriza** la conjunta y **codifica** independencias.



Dirigidos — redes bayesianas

Aristas con dirección y sin ciclos: dependencia *asimétrica*, a menudo causal. Factorizan en probabilidades condicionales, ya normalizadas.



No dirigidos — campos de Markov

Aristas simétricas. Factorizan en *potenciales* sobre cliques, con una constante global Z que suele ser intratable. Útiles cuando no hay dirección natural.

En esta clase nos quedamos con los **dirigidos**: son los que reemplazan al motor de reglas con incertidumbre.

Definición

Una **red bayesiana** sobre $X_1, \dots, X_n$ es un par $(\mathcal{G}, \Theta)$: un **grafo dirigido acíclico** (DAG) con un nodo por variable —escribimos $\text{Pa}(X_i)$ para los padres de X_i — y una **distribución condicional** $P(X_i \mid \text{Pa}(X_i))$ por nodo (si es discreta, una tabla: una CPT).

Semántica: regla de la cadena para redes bayesianas

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Pa}(X_i))$$

Cómo leerla. Es la regla de la cadena en la que cada conjunto condicionante $\{X_1, \dots, X_{i-1}\}$ se ha *podado* hasta dejar solo los padres. La red es exactamente esa lista de podas.


Afirmación equivalente (Markov local).

$$X_i \perp\!\!\!\perp \text{NoDesc}(X_i) \mid \text{Pa}(X_i)$$

Dados sus padres, un nodo es independiente de todo lo que no sea descendiente suyo.

Idea clave: Factorizar e independizar son **la misma afirmación**: P factoriza sobre $\mathcal{G}$ si y solo si P satisface la propiedad de Markov local de $\mathcal{G}$.

Un ejemplo clínico



$P(C)$	
sí	0,10

$P(A)$	
sí	0,20

C	$P(G=\text{sí} C)$
sí	0,40
no	0,02

G	$P(F=\text{sí} G)$
sí	0,90
no	0,05

G	A	$P(T=\text{sí} G, A)$
sí	sí	0,95
sí	no	0,85
no	sí	0,70
no	no	0,05

$$P(C, A, G, F, T) = P(C) P(A) P(G|C) P(F|G) P(T|G, A)$$

Las cinco variables son binarias. El grafo dice, por ejemplo, que *el contacto solo importa a través de la gripe* y que *la alergia no afecta a la fiebre*.

Evaluar una entrada de la conjunta es multiplicar cinco números locales:

$$\begin{aligned} P(c, \neg a, g, f, t) \\ &= \underbrace{0,10}_{P(c)} \cdot \underbrace{0,80}_{P(\neg a)} \cdot \underbrace{0,40}_{P(g|c)} \cdot \underbrace{0,90}_{P(f|g)} \cdot \underbrace{0,85}_{P(t|g\neg a)} \\ &= 0,0245 \end{aligned}$$

	conjunta plena	red bayesiana
$n = 5$	31	10
$n = 10$	1 023	~ 30
$n = 30$	10^9	~ 100

De dónde sale el ahorro

Un nodo con k padres binarios cuesta 2^k parámetros, no 2^{n-1} . El costo total es

$$\sum_{i=1}^n 2^{|\text{Pa}(X_i)|} \quad \text{en vez de} \quad 2^n - 1.$$


Si el número de padres está acotado por k , la red es **lineal** en n : $\mathcal{O}(n2^k)$.

El precio

El ahorro es exactamente el conjunto de independencias que hemos *afirmado*. Si una de ellas es falsa en el dominio, el modelo está mal, no solo comprimido.


Estructura e independencia: las tres conexiones

Toda ruta entre dos nodos pasa por uno de estos tres patrones. Verde = variable **observada**.




$$X \not\perp\!\!\!\perp Y$$
$$X \perp\!\!\!\perp Y \mid Z$$

la gripe transmite
el efecto del contacto



$$X \not\perp\!\!\!\perp Y$$
$$X \perp\!\!\!\perp Y \mid Z$$

fiebre y tos correlacionan
solo por la gripe




$$X \perp\!\!\!\perp Y$$
$$X \not\perp\!\!\!\perp Y \mid Z$$

gripe y alergia se vuelven
dependientes al ver la tos

Idea clave: Condicionar **bloquea** una cadena y una bifurcación, pero **abre** un colisionador. Es el único caso en que observar una variable crea dependencia donde no la había, y es la razón de que la lectura ingenua “más evidencia, más independencia” sea falsa.

Sobre la red del ejemplo, seguimos la creencia en **gripe**:



- ▶ A priori, $P(G) = 0,058$.
- ▶ Observar **tos** sube la creencia a 0,229: la tos es evidencia de gripe.
- ▶ Observar además que el paciente es **alérgico** la baja a 0,077: la alergia *ya explica* la tos, así que la gripe deja de hacer falta.

Por qué importa

Un motor de reglas con factores de certeza no puede hacer esto: sus reglas solo *suman* evidencia a favor. Aquí una evidencia **resta** creencia a una hipótesis rival sin que nadie escribiera una regla para ello: sale de la estructura.

Ruta bloqueada

Una ruta (no dirigida) entre X e Y está **bloqueada** por un conjunto de evidencia Z si contiene algún nodo W tal que:


Patrón en la ruta	Bloquea cuando
cadena $\rightarrow W \rightarrow$ o bifurcación $\leftarrow W \rightarrow$	$W \in Z$
colisionador $\rightarrow W \leftarrow$	$W \notin Z$ y ningún descendiente de W está en Z

X d-separado de Y dado $Z \implies X \perp\!\!\!\perp Y \mid Z$ en toda P que factorice sobre $\mathcal{G}$

Todas las rutas deben estar bloqueadas: basta una abierta para que el grafo no garantice independencia.

Cuidado con los descendientes. Si la tos provoca *consulta médica* y observamos la consulta, el colisionador se abre igual.

Idea clave: La d-separación convierte una pregunta probabilística en un problema de **caminos en un grafo**: se responde mirando el dibujo, sin tocar un solo número.



Definición

El **manto de Markov** de X es el conjunto formado por:

- ▶ sus **padres**,
- ▶ sus **hijos**,
- ▶ los **otros padres de sus hijos**.

$$X \perp\!\!\!\perp \text{ resto de la red } \mid \text{MB}(X)$$

Los otros padres entran porque cada hijo es un **colisionador**: observarlo abre la ruta hacia ellos.

Idea clave: El manto es la “interfaz” de una variable con el resto del modelo: para actualizar X basta mirar su vecindad. Es lo que hace local el cómputo en muestreo de Gibbs y en propagación de creencias.

Qué afirma el grafo (y qué no)


El grafo es un *I-map*

Toda independencia que el grafo declara (por d-separación) se cumple en P . Lo recíproco **no** vale: P puede tener independencias adicionales que el grafo no muestra.

Consecuencias prácticas

- ▶ Una **arista de más** nunca hace incorrecto el modelo: solo lo hace más caro y más difícil de estimar.
- ▶ Una **arista de menos** sí lo hace incorrecto: afirma una independencia falsa.
- ▶ El grafo completo es un *I-map* de cualquier P , y es inútil.
- ▶ No siempre existe un *P-map*: hay distribuciones cuyo conjunto exacto de independencias ningún DAG reproduce.

El orden de las variables importa. La misma distribución, construida con dos órdenes distintos:



Ambas representan *la misma* conjunta. Ordenar de causas a efectos produce el grafo más disperso y las tablas más fáciles de rellenar.

Tipos de consulta

- ▶ **Marginal a posteriori:** $P(G \mid F=\text{sí}, T=\text{sí})$.
- ▶ **MAP:** la asignación conjunta más probable de las variables no observadas.
- ▶ **Diagnóstico** (efecto $\rightarrow$ causa) y **predicción** (causa $\rightarrow$ efecto) usan *el mismo* modelo: la red no tiene una dirección privilegiada de uso, a diferencia del motor de reglas.

Cómo se calcula

- ▶ **Exacta:** eliminación de variables, árbol de uniones. Costo exponencial en el *ancho de árbol* del grafo, no en n .
- ▶ **Aproximada:** muestreo (rechazo, ponderación por verosimilitud, Gibbs) o métodos variacionales.
- ▶ El problema general es **NP-difícil**, también en su versión aproximada. En la práctica se explota que las redes reales son dispersas.

Herramientas: pgmpy (Python), bnlearn (R), Samlam y GeNIe para modelar y consultar de forma interactiva.

Idea clave: Una red bayesiana es una **base de conocimiento declarativa** como la de un sistema experto, pero con una semántica probabilística: el motor de inferencia deja de encadenar reglas y pasa a marginalizar.

Cómo modelar una situación real: receta

1. **Escribe primero la consulta.** ¿Qué se va a preguntar y qué se va a observar? Eso decide qué variables existen; todo lo demás sobra.
2. **Define las variables.** Estados **exhaustivos y mutuamente excluyentes**. Prefiere pocos estados: cada uno multiplica el tamaño de las CPT de los hijos.
3. **Ordena de causas a efectos.** Enfermedad antes que síntoma, falla antes que alarma. Ese orden da el grafo más disperso.
4. **Dibuja las aristas.** Para cada par, pregunta: *conocidos los padres ya elegidos, ¿saber X cambia mi creencia sobre Y ?* Si no, no hay arista.
5. **Verifica las independencias implicadas.** Recorre las aristas ausentes y comprueba con d-separación que lo que afirmas es defendible en el dominio.
6. **Rellena las CPT.** Datos donde los haya; elicitación experta donde no. Con muchos padres, usa modelos canónicos (*noisy-OR*, *noisy-MAX*) que necesitan k números en vez de 2^k .
7. **Valida.** Casos extremos (todo presente / todo ausente), análisis de sensibilidad, y comprueba que aparece el *explaining away* donde el experto lo espera.

Idea clave: Modelar es iterar entre los pasos 4 y 7. La primera red nunca es la buena; lo valioso es que cada corrección es **local**: se toca un nodo y sus tablas, no todo el sistema.

Aristas en dirección diagnóstica

Dibujar *síntoma* → *enfermedad* porque así razona el médico: la enfermedad acumula decenas de padres y las CPT explotan. Dibuja la causalidad; la inferencia ya invierte sola.

Confundir arista con correlación

Dos variables correlacionadas pueden no necesitar arista si una causa común ya explica la asociación.

Discretizar demasiado fino

Diez niveles de temperatura con tres padres son $10 \cdot 2^3$ celdas que rellenar. Usa los cortes que el experto distingue.

Olvidar las variables latentes

Si dos síntomas correlacionan sin causa modelada, la red los hará depender por caminos absurdos. Suele faltar un nodo no observable que capture la causa común.


Sesgo de selección

Con datos de pacientes ya hospitalizados se condiciona sobre un **colisionador** (*ingresó al hospital*): aparecen dependencias espurias entre enfermedades independientes en la población.

Regla de bolsillo

Ante la duda, **añade** la arista: sobran parámetros, pero no miente.

Auge y caída, en una lámina



- ▶ **DENDRAL** (desde 1965) infería estructuras moleculares a partir de espectrometría de masas: el primer sistema que codificó heurísticas de un especialista.
- ▶ **MYCIN** (1972–76) diagnosticaba infecciones bacterianas con unas 600 reglas y encadenamiento hacia atrás. Igualó a especialistas humanos en evaluaciones ciegas y **nunca se usó clínicamente**: problemas de responsabilidad legal y de integración.
- ▶ **XCON** configuraba pedidos de computadores VAX en DEC; creció hasta varios miles de reglas y se le atribuyeron ahorros del orden de decenas de millones de dólares al año.

El cuello de botella del conocimiento

Extraer reglas de un especialista es lento y caro. Buena parte de la pericia es **tácita**: el experto sabe hacerlo, pero no sabe enunciar la regla.

Mantenimiento

Con miles de reglas aparecen contradicciones, redundancias y efectos de orden. Cada cambio puede romper conclusiones lejanas.

Fragilidad en los bordes

Fuera de su dominio no degradan con elegancia: fallan en seco. No tienen sentido común.

El contraste que vendría

El aprendizaje automático ataca exactamente ese cuello de botella: en vez de *entrevistar* al experto, **induce** las regularidades desde los datos. A cambio, pierde la traza explicativa.

El colapso del mercado de máquinas Lisp hacia 1987 marcó el inicio del segundo invierno de la IA que vimos en la clase anterior.

Motores de reglas en producción

CLIPS, Drools y los motores de reglas de negocio siguen operando donde la lógica debe ser **auditable**: normativa tributaria, seguros, control de procesos.

IA explicable (XAI)

La capacidad de justificar una conclusión paso a paso, que los sistemas expertos tenían gratis, hoy es un área de investigación activa.

Sistemas híbridos y neuro-simbólicos

Un modelo neuronal propone; un componente simbólico verifica contra restricciones duras. Es la arquitectura de los asistentes que llaman herramientas y consultan bases de datos.

Lectura para el resto del curso

Cuando un LLM invoca una herramienta o un verificador, está reponiendo justo lo que el paradigma conexionista no trae: conocimiento **explícito** y **comprobable**.

Concepto	Idea clave
Sistema experto	Dominio estrecho + conocimiento declarado explícitamente
Arquitectura	Conocimiento (reglas) separado del control (motor)
Lógica proposicional	Proposiciones, conectivas y tablas de verdad
Modelo	Una asignación de verdad; hay 2^n de ellas
$\rightarrow$ vs. $\models$	Conectiva vs. relación entre conjuntos de modelos
Inferencia	Aplicar reglas en vez de enumerar mundos
Encadenamiento	Adelante: lo empujan los datos. Atrás: tira la meta
Incertidumbre	Factores de certeza: ingeniería, no probabilidad
Red bayesiana	DAG + una CPD por nodo: $P(X) = \prod_i P(X_i \mid \text{Pa}(X_i))$
Semántica	Factorizar $\equiv$ afirmar independencias condicionales
Tres conexiones	Cadena y bifurcación se bloquean al observar; el colisionador se abre
d-separación	Independencia leída como bloqueo de caminos en el grafo
Límite	El cuello de botella de la adquisición de conocimiento

- El conocimiento explícito da **trazabilidad**; el aprendizaje desde datos da **escala**. El curso avanza ahora hacia el segundo, sin olvidar lo que se pierde.
- Las redes bayesianas están en el medio: conocimiento **declarativo y auditable**, pero con semántica probabilística y parámetros que pueden **aprenderse de los datos**.

- ▶ Russell & Norvig, *Artificial Intelligence: A Modern Approach*, cap. 7–9 (agentes lógicos, lógica de primer orden, inferencia).
- ▶ Buchanan & Shortliffe (1984), *Rule-Based Expert Systems: The MYCIN Experiments*
<https://www.shortliffe.net/Buchanan-Shortliffe-1984/MYCIN%20Book.htm>
- ▶ Jackson (1998), *Introduction to Expert Systems*, 3.^a ed.
- ▶ Pearl (1988), *Probabilistic Reasoning in Intelligent Systems* — el libro que introdujo las redes bayesianas. Russell & Norvig, cap. 12–13, es la versión breve.
- ▶ Koller & Friedman (2009), *Probabilistic Graphical Models*, cap. 3: semántica del grafo y d-separación.
- ▶ Darwiche (2009), *Modeling and Reasoning with Bayesian Networks*, cap. 5: cómo *construir* la red.
- ▶ pgmpy, redes bayesianas en Python <https://pgmpy.org/>
- ▶ McDermott (1982), *R1: A rule-based configurer of computer systems*, *Artificial Intelligence* 19(1).
- ▶ CS50's *Introduction to AI with Python*, Harvard — lecciones *Knowledge y Uncertainty*
<https://cs50.harvard.edu/ai/>
- ▶ CLIPS, motor de reglas de la NASA <https://www.clipsrules.net/>

¿Preguntas?