


# Redes Neuronales

Sergio Hernández. PhD Computer Science

Magister en Data Science. Universidad Católica del Maule

## Red Neuronal

- El cerebro humano tiene cerca de  $10^{11}$  neuronas, las cuales funcionan como unidades independientes de cómputo localmente conectadas.
- La cantidad total de conexiones es de  $10^{14}$  y tienen el objetivo de crear un mapa entre la realidad y la representación interna al interior del cerebro.



## Agente Inteligente

Se dice que un agente es capaz de aprender si dado un **modelo** y cierto criterio de optimización, este mejora su desempeño al recibir nueva información.

## Aprendizaje

El agente toma datos de un conjunto de **entrenamiento** y construye el mejor mapa posible entre las características que discriminan cierto elemento.

Una vez que el agente recoge nuevos datos para el cual no conoce su correcta asociación, es capaz de utilizar el modelo para **generalizar** lo que ha aprendido.

# Aprendizaje Supervisado

Dado un conjunto de datos  $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ , la variable  $x$  representa la variable independiente y  $y$  la variable dependiente. La regresión y la clasificación son dos tipos de tareas de aprendizaje supervisado, pero se diferencian en la naturaleza de la variable objetivo  $y$ .

## Clasificación

El objetivo es asignar datos a categorías pre-definidas (clases discretas  $y \in \{c_1, c_2, \dots, c_k\}$ ).

## Regresión

El objetivo es predecir un valor numérico continuo ( $y \in \mathbb{R}$ ).

## Ejemplo : Regresión polinomial

- En el caso de problemas de regresión no-lineal simple, es posible ajustar mediante polinomios de orden  $p$ .

$$\begin{aligned}y &= f(x) + \epsilon \\ &= w_0 + \sum_{j=1}^p w_j x^j + \mathcal{N}(0, \sigma^2)\end{aligned}$$



## Ejemplo : Regresión polinomial

- En el caso de problemas de regresión no-lineal simple, es posible ajustar mediante polinomios de orden  $p$ .

$$\begin{aligned}y &= f(x) + \epsilon \\&= w_0 + \sum_{j=1}^p w_j x^j + \mathcal{N}(0, \sigma^2)\end{aligned}$$


- Es posible determinar los parámetros del polinomio  $\mathbf{w} = [w_0, \dots, w_p]$  mediante el método de mínimos cuadrados  $E_p(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2$ .

# Regresión polinomial: Selección del modelo




# Regresión polinomial: Sobreajuste

Sub-ajuste



$$y = \sum_{i=0}^1 w_i x^i$$

Sobreajuste



$$y = \sum_{i=0}^7 w_i x^i$$

## Selección de Modelo

La selección del orden  $p$  está relacionada con la capacidad de ajuste y de generalización del modelo.



# Perceptrón

- En el caso de problemas de clasificación binaria multi-variable, las variable de entrada toman valores  $\mathbf{x} \in \mathbb{R}_D$  y  $y \in \{-1, 1\}$ . Los parámetros  $w_j$  se conocen pesos y  $w_0$  como sesgo o bias.

$$\begin{aligned} f(\mathbf{x}) &= f\left(w_0 + \sum_{j=1}^D w_j x_j\right) \\ &= f(\mathbf{w}^T \mathbf{x}) \end{aligned}$$

# Perceptrón

- En el caso de problemas de clasificación binaria multi-variable, las variable de entrada toman valores  $\mathbf{x} \in \mathbb{R}_D$  y  $y \in \{-1, 1\}$ . Los parámetros  $w_j$  se conocen pesos y  $w_0$  como sesgo o bias.

$$\begin{aligned} f(\mathbf{x}) &= f\left(w_0 + \sum_{j=1}^D w_j x_j\right) \\ &= f(\mathbf{w}^T \mathbf{x}) \end{aligned}$$

- El peceptrón (Rosenblatt, 1962) es un tipo de discriminante lineal que utiliza la siguiente regla:

$$f(\mathbf{x}) = \begin{cases} +1 & \mathbf{w}^T \mathbf{x} \geq 0 \\ -1 & \mathbf{w}^T \mathbf{x} < 0 \end{cases} \quad (1)$$

(2)

# Regla de Aprendizaje del Perceptrón

- El objetivo del perceptrón es asignar cero error a cualquier patrón de entrada que es clasificado de manera correcta. En cambio, para los patrones incorrectamente clasificados ( $x_i \in \mathcal{M}$ ), minimizamos la cantidad  $-\mathbf{w}^T \mathbf{x}_i y_i$
- Por lo tanto, para entrenar el perceptrón, necesitamos encontrar los pesos  $\mathbf{w}$  que minimicen el error  $E(\mathbf{w}) = -\sum_{i \in \mathcal{M}} \mathbf{w}^T \mathbf{x}_i y_i$ .
- El entrenamiento del algoritmo utiliza un método iterativo conocido como **Descenso del Gradiente**:


$$\begin{aligned}\mathbf{w}^{\tau+1} &= \mathbf{w}^{\tau} - \eta \nabla E(\mathbf{w}^{\tau}) \\ &= \mathbf{w}^{\tau} + \eta \sum_{i \in \mathcal{M}} \mathbf{x}_i y_i\end{aligned}$$

- $\eta$  es la *tasa de aprendizaje*, y  $\tau$  es el número de iteración.

# Regla de Aprendizaje del Perceptrón

## Perceptrón

- El teorema de convergencia del perceptrón muestra que si las clases son linealmente separables, entonces la regla de aprendizaje garantiza encontrar una solución en tiempo finito.
- En la práctica, la convergencia es lenta y el algoritmo no puede ser extendido para clases múltiples.



# Clasificación Probabilística

- Ahora, nos interesa la probabilidad condicional  $p(y = 1|\mathbf{x})$ , para estimar probabilidades de clase.

$$\log \left( \frac{p(y = 1|\mathbf{x})}{p(y = 0|\mathbf{x})} \right) = \mathbf{w}^T \mathbf{x}$$

# Clasificación Probabilística

- Ahora, nos interesa la probabilidad condicional  $p(y = 1|\mathbf{x})$ , para estimar probabilidades de clase.

$$\log \left( \frac{p(y = 1|\mathbf{x})}{p(y = 0|\mathbf{x})} \right) = \mathbf{w}^T \mathbf{x}$$


- Podemos obtener las probabilidades condicionales para cada clase:

$$\begin{aligned} p(y = 1|\mathbf{x}) &= \phi(\mathbf{w}^T \mathbf{x}) = \frac{\exp(\mathbf{w}^T \mathbf{x})}{1 + \exp(\mathbf{w}^T \mathbf{x})} \\ &= \frac{1}{1 + \exp(\mathbf{w}^T \mathbf{x})} \\ p(y = 0|\mathbf{x}) &= 1 - p(y = 1|\mathbf{x}) \end{aligned}$$

# Función Sigmoide

## Sigmoide

- La función  $\phi(\mathbf{w}^T \mathbf{x}) : \mathbb{R} \mapsto [0, 1]$  produce salidas en el intervalo  $[0, 1]$ .
- La función  $\phi(\mathbf{w}^T \mathbf{x})$  es continua y diferenciable, por lo tanto es posible utilizar el Descenso del Gradiente.
- La función de pérdida  $E(\mathbf{w})$  es el negativo del logaritmo de la distribución de Bernoulli.



$$\frac{\partial \phi}{\partial \mathbf{w}} = \phi(\mathbf{w}^T \mathbf{x}) \times (1 - \phi(\mathbf{w}^T \mathbf{x}))$$

$$E(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n -y_i \log \phi(\mathbf{x}_i) - (1 - y_i) \log(1 - \phi(\mathbf{x}_i))$$

# Conclusiones

- El perceptrón es un modelo de neurona artificial que puede clasificar datos en dos clases.
- La regla de aprendizaje del perceptrón ajusta los pesos de una combinación lineal de las entradas, tal que en cada iteración se minimiza el error de clasificación.
- Este modelo no puede resolver problemas complejos con fronteras de decisión no-lineales.