

Redes Neuronales

Sergio Hernández. PhD Computer Science

Magister en Data Science. Universidad Católica del Maule

¿Qué es una Función de Pérdida?

Definición

Una función de pérdida $\mathcal{L}(y, \hat{y})$ cuantifica la discrepancia entre la predicción de un modelo ($\hat{y}$) y el valor real (y). Su objetivo es guiar la optimización de los parámetros del modelo (θ) para minimizar esta diferencia.

$$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N \mathcal{L}(y_i, f(x_i; \theta))$$

Pérdida vs. Métrica de Desempeño

- **Función de Pérdida:** Usada durante el **entrenamiento** para optimizar los parámetros. Debe ser (sub)diferenciable.
- **Métrica de Desempeño:** Usada **después** del entrenamiento para **evaluar** la generalización del modelo. No necesita ser diferenciable y suele ser más interpretable para los humanos (ej. Accuracy, IoU).

Propiedades de una Función de Pérdida

Al seleccionar una función de pérdida, consideramos varias propiedades clave:

- **Diferenciabilidad:** Permite el uso de métodos de optimización basados en gradiente, el pilar del deep learning.

Propiedades de una Función de Pérdida

Al seleccionar una función de pérdida, consideramos varias propiedades clave:

- **Diferenciabilidad:** Permite el uso de métodos de optimización basados en gradiente, el pilar del deep learning.
- **Convexidad:** Una pérdida convexa garantiza que cualquier mínimo local es también el mínimo global. En redes neuronales, la superficie de pérdida es no-convexa, pero la convexidad local sigue siendo útil.

Propiedades de una Función de Pérdida

Al seleccionar una función de pérdida, consideramos varias propiedades clave:

- **Diferenciabilidad:** Permite el uso de métodos de optimización basados en gradiente, el pilar del deep learning.
- **Convexidad:** Una pérdida convexa garantiza que cualquier mínimo local es también el mínimo global. En redes neuronales, la superficie de pérdida es no-convexa, pero la convexidad local sigue siendo útil.
- **Robustez:** La capacidad de manejar valores atípicos (outliers) sin que afecten desproporcionadamente al gradiente.

Pérdidas de Regresión

MSE (L2 Loss):


$$\mathcal{L}_{MSE} = (y - \hat{y})^2$$

MAE (L1 Loss):


$$\mathcal{L}_{MAE} = |y - \hat{y}|$$

Huber Loss:

$$\mathcal{L}_{\delta} = \begin{cases} \frac{1}{2}(y - \hat{y})^2 & \text{si } |y - \hat{y}| \leq \delta \\ \dots & \text{en otro caso} \end{cases}$$




Negativo Logaritmo Verosimilitud (NLL) Regresión



$$y \sim \mathcal{N}(\mu, \sigma^2)$$

$$Pr(y|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y-\mu)^2}{2\sigma^2} \right]$$

$$\mathcal{L}_{NLL} = \frac{1}{2} \sum_{i=1}^D \left(\log(\sigma_i^2) + \frac{(y_i - \mu_i)^2}{\sigma_i^2} \right)$$



Entropía Cruzada (Cross-Entropy)

Es la función de pérdida estándar para tareas de clasificación. Mide la divergencia entre la distribución de probabilidad predicha y la distribución verdadera (one-hot).


Binaria (BCE): Para dos clases.

$$\mathcal{L}_{BCE} = -[y \log(\hat{p}) + (1 - y) \log(1 - \hat{p})]$$

Categorica (CCE): Para múltiples clases.

$$\mathcal{L}_{CCE} = - \sum_{j=1}^C y_j \log(\hat{p}_j)$$


Negativo Logaritmo Verosimilitud (NLL) Clasificación



$$y \sim \text{Multinomial}(1; p_1, p_2, p_3).$$

$$p_i = \frac{\exp(w^T x)}{\sum_{c=1}^3 \exp(w^T x)}$$

$$\mathcal{L}_{NLL} = -\frac{1}{D} \sum_{i=1}^D \sum_{j=1}^3 y_{ij} \log(\hat{p}_{ij})$$



Desbalance de Clases

Entropía Cruzada Ponderada (Weighted Cross-Entropy)

Asigna un peso mayor a la pérdida de las clases minoritarias. Es una solución simple y efectiva.

$$\mathcal{L}_{WCE} = - \sum_{j=1}^C \alpha_j y_j \log(\hat{p}_j)$$

donde α_j es inversamente proporcional a la frecuencia de la clase j .

Pérdida Focal (Focal Loss)

Una mejora sobre WCE que añade un factor de modulación para reducir la contribución de los ejemplos "fáciles" (bien clasificados).


$$\mathcal{L}_{FL} = -(1 - p_t)^\gamma \log(p_t)$$

Esto fuerza al modelo a centrarse en los ejemplos difíciles, que a menudo pertenecen a las clases minoritarias.

Detección de Objetos: Un Problema Compuesto

La detección de objetos es una tarea multi-objetivo que requiere:

- 1 **Clasificación:** ¿Qué objeto hay en la caja?
- 2 **Localización:** ¿Dónde está la caja (bounding box)?



Pérdida Compuesta

La función de pérdida total es una suma ponderada de una pérdida de clasificación y una pérdida de regresión.

$$\mathcal{L}_{total} = \mathcal{L}_{cls} + \lambda \mathcal{L}_{reg}$$

- $\mathcal{L}_{cls}$ suele ser Entropía Cruzada o Focal Loss.
- $\mathcal{L}_{reg}$ se especializa en la regresión de las coordenadas de la caja.

Pérdidas para la Regresión de Bounding Box


Smooth L1 Loss

Una variante de la pérdida de Huber, es el estándar de facto en muchos detectores de dos etapas como Faster R-CNN. Es robusta a outliers pero suave cerca de cero.

Pérdidas basadas en IoU (Intersection over Union)

Optimizan directamente la métrica de evaluación principal: el solapamiento entre la caja predicha (B_p) y la real (B_t).

$$\text{IoU} = \frac{\text{Area}(B_p \cap B_t)}{\text{Area}(B_p \cup B_t)} \implies \mathcal{L}_{IoU} = 1 - \text{IoU}$$



Reconocimiento Facial: Aprendizaje Métrico

El objetivo no es solo clasificar, sino aprender un **espacio de embedding** donde:

- Las distancias **intra-clase** (entre caras de la misma persona) sean pequeñas.
- Las distancias **inter-clase** (entre caras de personas diferentes) sean grandes.

Pérdidas Basadas en Margen Angular

En lugar de optimizar logits, estas pérdidas operan directamente sobre el ángulo entre el embedding de una cara y el vector prototipo de su clase.

- **CosFace**: Introduce un margen aditivo en el espacio del coseno.
- **ArcFace**: Introduce un margen aditivo directamente en el ángulo.

Pérdida de Triplete (Triplet Loss)

Una pérdida clásica de aprendizaje métrico que no requiere un número fijo de clases.

Formulación

Se consideran tres ejemplos: un **ancla** (A), un **positivo** (P , misma identidad) y un **negativo** (N , identidad diferente). La pérdida busca que la distancia del ancla al positivo sea menor que la distancia al negativo, por un margen α .

$$\mathcal{L}_{Triplet} = \max \left(0, \underbrace{\|f(A) - f(P)\|_2^2}_{\text{distancia positiva}} - \underbrace{\|f(A) - f(N)\|_2^2}_{\text{distancia negativa}} + \alpha \right)$$

Conclusiones

- La elección de la función de pérdida es una decisión de diseño fundamental que define el objetivo de la optimización y tiene un impacto directo en el rendimiento del modelo.
- No existe una "bala de plata". La pérdida ideal depende de la tarea (**regresión, clasificación**), las características de los datos (**outliers, desbalance**) y la métrica de evaluación final.
- Tareas complejas como la **detección de objetos** o el **reconocimiento facial** han impulsado el desarrollo de pérdidas especializadas (basadas en IoU, aprendizaje métrico) que van más allá de las formulaciones estándar.
- El futuro de la investigación se dirige hacia la **búsqueda automatizada** de funciones de pérdida y el diseño de objetivos que incorporen **robustez, interpretabilidad y equidad**.