

Redes Neuronales

Máxima verosimilitud y función de pérdida

Sergio Hernández, PhD
shernandez@ucm.cl

l




Magíster en Data Science — Universidad Católica del Maule


- ▶ En el aprendizaje supervisado, buscamos entrenar un **modelo** $f(x)$ que mapee una entrada x a una salida y .
- ▶ θ representa los **parámetros** del modelo, definiendo una función específica dentro de una familia de funciones.
- ▶ **¿Cómo sabemos qué tan "bueno" es nuestro mapeo?** Aquí es donde entran las **funciones de pérdida** $L[\theta]$.
- ▶ Una función de pérdida cuantifica la **discrepancia** entre las predicciones del modelo $f(x)$ y las salidas reales y_i de nuestro conjunto de datos de entrenamiento $\{x_i, y_i\}$.
- ▶ **El objetivo del entrenamiento** es encontrar los valores de ϕ que **minimizan** esta función de pérdida, logrando así el "mejor mapeo posible".

- ▶ En lugar de que el modelo prediga directamente y , adoptamos una perspectiva donde el modelo $f(x)$ predice una **distribución de probabilidad condicional** $Pr(y|x)$ sobre las posibles salidas y .
- ▶ **Elección de una Distribución Paramétrica:**
 - ▶ Se selecciona una distribución de probabilidad $Pr(y|\theta)$ adecuada para el dominio de la salida y (clasificación, regresión, ranking).
 - ▶ Por ejemplo, para problemas de regresión con salida real $y \in \mathbb{R}$, la **distribución normal univariada** (Gaussiana) es una opción común. Esta se define por su media μ y varianza σ^2 . Así, $\theta = \{\mu, \sigma^2\}$.
 - ▶ El modelo $f(x)$ podría, por ejemplo, predecir la media μ , y σ^2 podría ser un parámetro fijo o también aprendido.



Máxima Verosimilitud



$$y \sim \mathcal{N}(\mu, \sigma^2)$$



$$\omega_1 * \mathcal{N}(\mu_1, \sigma_1) + \omega_2 * \mathcal{N}(\mu_2, \sigma_2)$$



El Principio de Máxima Verosimilitud

Formulación del Criterio (MLE)

- ▶ Para cada ejemplo de entrenamiento x_i , el modelo computa los parámetros de la distribución $\theta_i = f[x_i, \phi]$.
- ▶ Idealmente, cada salida observada y_i debería tener una **alta probabilidad** bajo la distribución $Pr(y_i|\theta_i)$ que corresponde a x_i .
- ▶ El objetivo es elegir los parámetros ϕ que **maximizan la probabilidad conjunta** de todas las observaciones de entrenamiento:

$$\hat{\phi} = \underset{\phi}{\operatorname{argmax}} \prod_{i=1}^I Pr(y_i|f[x_i, \phi]) \quad (5.1)$$

- ▶ Esta expresión se conoce como el **criterio de máxima verosimilitud (MLE)**.

El Principio de Máxima Verosimilitud

Supuestos Clave y la Log-Verosimilitud

► Supuestos Implícitos del MLE:

1. Los datos son **independientes e idénticamente distribuidos (i.i.d.)**: Esto significa que la forma de la distribución $Pr(y_i|x_i)$ es la misma para cada punto de datos, y las observaciones son independientes entre sí.

$$Pr(y_1, \dots, y_I | x_1, \dots, x_I) = \prod_{i=1}^I Pr(y_i | x_i) \quad (5.2)$$

- ### ► Problema Práctico con el Producto:
- El producto de muchas probabilidades pequeñas (cada $Pr(y_i|x_i)$ es ≤ 1) puede resultar en un número extremadamente diminuto, lo que causa problemas de **precisión numérica**.

► Solución: Maximizar la Log-Verosimilitud:

- El logaritmo es una función **monotónicamente creciente**.
- Esto implica que maximizar una función $g[z]$ es equivalente a maximizar $\log(g[z])$. El máximo ocurre en la misma posición.
- *Visualización (se podría usar TikZ)*: Muestre una función $g(z)$ y su $\log(g(z))$, resaltando que los picos coinciden (similar a la Figura 5.2 del material).
- Por lo tanto, podemos maximizar la **log-verosimilitud**:

$$\hat{\phi} = \underset{\phi}{\operatorname{argmax}} \sum_{i=1}^I \log[Pr(y_i | f[x_i, \phi])] \quad (5.3)$$

- La ventaja clave es que convertimos un **producto en una suma**, lo que es numéricamente mucho más estable.

La Función de Pérdida Final: NLL

Minimizando el Negativo de la Log-Verosimilitud

- ▶ Por convención en el aprendizaje automático, los problemas se formulan como **minimización de una función de costo**.
- ▶ Para transformar el criterio de máxima log-verosimilitud en un problema de minimización, simplemente lo **multiplicamos por menos uno**:

$$\hat{\phi} = \underset{\phi}{\operatorname{argmin}} \left[- \sum_{i=1}^I \log \operatorname{Pr}(y_i | f[x_i, \phi]) \right] \quad (5.4)$$

- ▶ Esta expresión define nuestra **función de pérdida final** $L[\theta]$.

- ▶ Una vez que el modelo ha sido entrenado y los parámetros ϕ están optimizados, ¿cómo obtenemos una predicción para una nueva entrada x ?
- ▶ El modelo no produce un valor y directamente, sino una distribución de probabilidad $Pr(y|f[x, \phi])$.
- ▶ A menudo, necesitamos una **estimación puntual** $\hat{y}$ en lugar de una distribución completa. Esto se logra encontrando el valor de y que **maximiza la probabilidad** de la distribución:

$$\hat{y} = \underset{y}{\operatorname{argmax}}[Pr(y|f[x, \phi])] \quad (5.5)$$

- ▶ Para la distribución normal univariada, el máximo de la distribución se encuentra en su **media** μ . Por lo tanto, para un modelo que predice la media, $\hat{y} = f[x, \phi]$.

Pasos Clave basados en Máxima Verosimilitud (Sección 5.2)

Para un conjunto de datos de entrenamiento $\{x_i, y_i\}$:

1. **Elegir una distribución de probabilidad** $Pr(y|\theta)$ adecuada para el dominio de las predicciones y , con sus parámetros θ .
2. **Configurar el modelo de aprendizaje automático** $f(x)$ para que prediga uno o más de estos parámetros. Es decir, $\theta = f[x, \phi]$ y por lo tanto $Pr(y|\theta) = Pr(y|f[x, \phi])$.
3. **Entrenar el modelo** encontrando los parámetros ϕ que minimizan la función de pérdida del negativo de la log-verosimilitud sobre los pares de datos de entrenamiento $\{x_i, y_i\}$:

$$\hat{\phi} = \underset{\phi}{\operatorname{argmin}} [L[\phi]] = \underset{\phi}{\operatorname{argmin}} \left[- \sum_{i=1}^I \log[Pr(y_i|f[x_i, \phi])] \right] \quad (5.6)$$

4. **Realizar inferencia** para un nuevo ejemplo de prueba x . Esto puede ser devolviendo la distribución completa $Pr(y|f[x, \phi])$ o el valor de y donde esta distribución se maximiza ($\hat{y}$).

Ejemplo: Regresión Univariada

Derivación de la Pérdida de Mínimos Cuadrados

- ▶ **Objetivo:** Predecir una salida escalar $y \in \mathbb{R}$ a partir de una entrada escalar x .
- ▶ **Distribución elegida:** La distribución normal univariada.
- ▶ **Función de Densidad de Probabilidad (PDF):**

$$Pr(y|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y - \mu)^2}{2\sigma^2} \right] \quad (5.7)$$

- ▶ **El modelo predice la media:** Sea $\mu = f[x, \phi]$. Entonces, la probabilidad condicional es:

$$Pr(y|f[x, \phi], \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y - f[x, \phi])^2}{2\sigma^2} \right] \quad (5.8)$$

Ejemplo: Regresión Univariada

Derivación de la Pérdida de Mínimos Cuadrados (Continuación)

- Aplicando el negativo de la log-verosimilitud (Ecuación 5.4):

$$\begin{aligned} L[\phi] &= - \sum_{i=1}^I \log [Pr(y_i | f[x_i, \phi], \sigma^2)] \\ &= - \sum_{i=1}^I \log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(y_i - f[x_i, \phi])^2}{2\sigma^2} \right) \right] \\ &= - \sum_{i=1}^I \left[\log \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) - \frac{(y_i - f[x_i, \phi])^2}{2\sigma^2} \right] \\ &= \sum_{i=1}^I \left[\frac{(y_i - f[x_i, \phi])^2}{2\sigma^2} - \log \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right) \right] \end{aligned} \quad (5.9)$$

- Al minimizar $L[\theta]$, podemos ignorar los términos que no dependen de ϕ (como σ^2 , si se asume constante) y el factor constante $1/(2\sigma^2)$:

$$\operatorname{argmin}_{\phi} L[\phi] \propto \operatorname{argmin}_{\phi} \sum_{i=1}^I (y_i - f[x_i, \phi])^2 \quad (5.10)$$

- El resultado es la conocida **función de pérdida de Mínimos Cuadrados**:

$$L[\phi] = \sum_{i=1}^I (y_i - f[x_i, \phi])^2 \quad (5.11)$$

- Esto demuestra cómo la pérdida de mínimos cuadrados surge naturalmente de asumir que los errores son independientes y están distribuidos normalmente alrededor de la predicción del modelo.

- ▶ Las **funciones de pérdida** son el motor del entrenamiento en el aprendizaje supervisado, transformando la "bondad" de un modelo en una cantidad optimizable.
- ▶ El **Principio de Máxima Verosimilitud** provee un marco teórico robusto para la construcción de estas funciones, al ver el modelo como un predictor de distribuciones de probabilidad.
- ▶ La utilización de la **log-verosimilitud negativa** resuelve problemas de estabilidad numérica y convierte la maximización en una minimización.
- ▶ La **pérdida de mínimos cuadrados** es un ejemplo clásico que surge directamente de asumir una distribución normal para los errores.
- ▶ La elección de la función de pérdida correcta es crucial y depende del tipo de problema (regresión, clasificación, etc.) y de las suposiciones sobre los datos.