

Optimización en Redes Neuronales


Sergio Hernández. PhD Computer Science

Magister en Data Science.
Universidad Católica del Maule

Superficie de Error

La función de pérdida $E(\theta) = \sum_i \mathcal{L}(y_i, \hat{y}_i)$ define una superficie de error sobre el espacio de todos los posibles parámetros θ .

- El objetivo de la optimización es encontrar el punto más bajo en esta superficie.
- Los algoritmos se basan en el **gradiente** $\nabla E(\theta)$, un vector que apunta en la dirección de máximo crecimiento del error. Nos movemos en la dirección opuesta: $-\nabla E(\theta)$



Optimización en Aprendizaje Profundo

1. Mínimos Locales: El algoritmo puede converger a un mínimo que no es el global, resultando en un modelo subóptimo. La naturaleza estocástica de SGD (mini-batches) ayuda a escapar.

2. Puntos de Silla: Puntos donde el gradiente es cero, pero no son un mínimo. En dimensiones altas, son **mucho más comunes** que los mínimos locales. En un punto de silla, la matriz Hessiana tiene autovalores positivos y negativos.




Figure: Visualización de un punto de silla $f(x, y) = x^2 - y^2$. El gradiente es cero en $(0, 0)$, pero no es un mínimo.

Optimización en Aprendizaje Profundo

3. Gradientes que se Desvanecen (Vanishing Gradients): En redes profundas, los gradientes pueden volverse extremadamente pequeños, deteniendo el aprendizaje.

- Causa: Multiplicación de números de-normalizados (underflow) en la regla de la cadena. Activaciones como la sigmoide o tanh son propensas a esto.

4. Gradientes que Explotan (Exploding Gradients): los gradientes crecen exponencialmente, causando inestabilidad.

- Causa: Multiplicación de números grandes (overflow).



Soluciones

Técnicas como **activaciones ReLU**, **Batch Normalization** y **Conexiones Residuales** fueron creadas para mitigar estos problemas.

Normalización de Datos

Normalización de Datos

La normalización de datos es una técnica de pre-procesamiento que se aplica sobre los datos de entrada para asegurar que la superficie de error tenga la misma curvatura en cada una de las dimensiones.



Batch Normalization (**BatchNorm**)

Normaliza las pre-activaciones dentro de cada capa para cada mini-lote de datos. Específicamente, para cada unidad oculta i , calcula la media y la varianza de sus pre-activaciones $x_{in}[i]$ a través de los ejemplos en el mini-lote actual y las utiliza para estandarizar los valores a una media de cero y una varianza unitaria


$$x_{out}[i] = \gamma \frac{x_{in}[i] - \mathbb{E}[x_{in}[i]]}{\sqrt{\text{Var}[x_{in}[i]]}} + \beta$$

Donde γ y β son parámetros entrenables.

Normalización de Capas

Layer Normalization (**LayerNorm**)

Existen otros tipos de normalización por capas. Por ejemplo, si calculamos la media $\mu = \frac{1}{d} \sum_i^d x_{in}[i]$ y varianza de la capa $\sigma^2 = \frac{1}{d} \sum_i^d (x_{in}[i] - \mu)^2$. A diferencia de BatchNorm, la media y varianza se calculan sobre los elementos $x_{in}[i]$.



Algoritmos de Descenso de Gradiente (GD)

Batch GD

Calcula el gradiente usando **todo** el dataset.

- Preciso pero computacionalmente inviable para datasets grandes.

Stochastic GD (SGD)


Calcula el gradiente usando **un solo** dato a la vez.

- + Rápido, eficiente y el ruido ayuda a escapar de mínimos locales.
- Actualizaciones muy ruidosas.

Stochastic GD (SGD)

$$\theta^{k+1} \leftarrow \theta^k - \eta \nabla E(\theta^k)$$

Descenso de Gradiente Estocástico (SGD)



Mini-batch SGD

Calcula el gradiente $\nabla_{\mathcal{B}_k} E(\theta^k)$ sobre un **pequeño lote** $|\mathcal{B}_k| \ll n$ (mini-batch) de datos.

- + Reduce el ruido y aprovecha la computación paralela (multi-GPU).
- + Para modelos grandes, es posible combinar paralelismo de datos y paralelismo de modelos.

Momentum

- Es una forma de solucionar el problema de valores propios de la matriz Hessiana es agregar un término de **momento**. Ayuda a acelerar en direcciones de baja curvatura y amortiguar oscilaciones .

$$\begin{aligned}\mathbf{v}^k &\leftarrow \beta \mathbf{v}^{k-1} - \eta E(\theta^k), \\ \theta^{k+1} &\leftarrow \theta^k + \mathbf{v}^k\end{aligned}$$

- **Nesterov:** Modifica el algoritmo de **momento**, utilizando el gradiente en una posición futura proyectada.

$$\mathbf{v}^{k+1} \leftarrow \beta \mathbf{v}^{k-1} - \eta E(\theta^k + \beta \mathbf{v}^k)$$

Algoritmos de Descenso de Gradiente (GD)






Figure: Y. Nesterov, A Method of Solving a Convex Programming Problem with Convergence Rate $O(1/k^2)$, Soviet Mathematics Doklady, vol. 27, no. 2, pp. 543–547, 1983.


Problema Inverso: Dado un conjunto finito de datos, existen infinitos modelos que podrían haberlos generado. ¿Cómo elegimos el correcto?



Sesgo y Varianza




Alto Sesgo, Baja Varianza




Bajo Sesgo, Alta Varianza

Sesgo y Varianza



Bajo Sesgo, Baja Varianza (Ideal)



Alto Sesgo, Alta Varianza

Problema Inverso: Dado un conjunto finito de datos, existen infinitos modelos que podrían haberlos generado. ¿Cómo elegimos el correcto?

Sesgo Inductivo (Inductive Bias)

Para generalizar, necesitamos introducir **suposiciones** o **conocimiento previo** sobre la naturaleza de la solución. Esto se llama *sesgo inductivo*.

- **Teorema de No Free Lunch (Wolpert, 1996)** : Ningún algoritmo es el mejor para todos los problemas. El éxito depende de que el sesgo inductivo del algoritmo coincida con el problema.
- La regularización es una forma de introducir un sesgo inductivo explícito.

Técnicas de Regularización Explícita

Weight Decay (Regularización L2)

Añade un término de penalización a la pérdida:

$$E(\theta) + \lambda ||\theta||_2$$

- **Sesgo inductivo:** Prefiere funciones "más suaves" (con pesos pequeños)
- Reduce la varianza del modelo a costa de un pequeño aumento en el sesgo

Data Augmentation

Aumenta artificialmente el dataset creando versiones transformadas de los datos (rotaciones, recortes, etc.).

- **Sesgo inductivo:** Enseña explícitamente al modelo a ser invariante a estas transformaciones .
- Extremadamente efectivo y fácil de implementar, especialmente para imágenes.

Técnicas de Regularización Explícita

Dropout

Durante el entrenamiento, "apaga" neuronas aleatoriamente con una probabilidad p .

- Previene la co-adaptación compleja entre neuronas.
- Es una forma eficiente de promediar un número exponencial de redes neuronales distintas (ensemble) .

Early Stopping

Monitoriza el error en un set de validación y detiene el entrenamiento cuando este error deja de mejorar.

- La forma más simple de regularización.
- Controla la complejidad efectiva del modelo, que aumenta con las épocas de entrenamiento.

- **Descenso del Gradiente** es algoritmo para encontrar un mínimo en la función de pérdida. El **momento** ayuda a controlar el efecto de los puntos silla.
- **La regularización** es una técnica para asegurar que ese mínimo corresponda a un modelo que generaliza. Se basa en el principio fundamental del *sesgo inductivo*.
- Las innovaciones modernas como **BatchNorm** y **LayerNorm** son poderosas porque mejoran tanto la optimización (haciendo el entrenamiento más fácil y rápido) como la regularización (llevando a mejores modelos).