

Optimización en Redes Neuronales

Descenso de gradiente y regularización

Sergio Hernández, PhD
shernandez@ucm.cl




Magíster en Data Science — Universidad Católica del Maule

Superficie de Error

La función de pérdida $E(\theta) = \sum_i \mathcal{L}(y_i, \hat{y}_i)$ define una superficie de error sobre el espacio de todos los posibles parámetros θ .

- ▶ El objetivo de la optimización es encontrar el punto más bajo en esta superficie.
- ▶ Los algoritmos se basan en el **gradiente** $\nabla E(\theta)$, un vector que apunta en la dirección de máximo crecimiento del error. Nos movemos en la dirección opuesta: $-\nabla E(\theta)$



- 1. Mínimos Locales:** El algoritmo puede converger a un mínimo que no es el global, resultando en un modelo subóptimo. La naturaleza estocástica de SGD (mini-batches) ayuda a escapar.
- 2. Puntos de Silla:** Puntos donde el gradiente es cero, pero no son un mínimo. En dimensiones altas, son **mucho más comunes** que los mínimos locales. En un punto de silla, la matriz Hessiana tiene autovalores positivos y negativos.




Figura: Visualización de un punto de silla $f(x, y) = x^2 - y^2$. El gradiente es cero en $(0,0)$, pero no es un mínimo.

3. Gradientes que se Desvanecen (Vanishing Gradients): En redes profundas, los gradientes pueden volverse extremadamente pequeños, deteniendo el aprendizaje.

- ▶ Causa: Multiplicación de números de-normalizados (underflow) en la regla de la cadena. Activaciones como la sigmoide o tanh son propensas a esto.

4. Gradientes que Explotan (Exploding Gradients): los gradientes crecen exponencialmente, causando inestabilidad.


- ▶ Causa: Multiplicación de números grandes (overflow).

Soluciones

Técnicas como **activaciones ReLU**, **Batch Normalization** y **Conexiones Residuales** fueron creadas para mitigar estos problemas.

Normalización de Datos

La normalización de datos es una técnica de pre-procesamiento que se aplica sobre los datos de entrada para asegurar que la superficie de error tenga la misma curvatura en cada una de las dimensiones.



Batch Normalization (BatchNorm)


Normaliza las pre-activaciones dentro de cada capa para cada mini-lote de datos. Específicamente, para cada unidad oculta i , calcula la media y la varianza de sus pre-activaciones $x_{in}[i]$ a través de los ejemplos en el mini-lote actual y las utiliza para estandarizar los valores a una media de cero y una varianza unitaria

$$x_{out}[i] = \gamma \frac{x_{in}[i] - \mathbb{E}[x_{in}[i]]}{\sqrt{\text{Var}[x_{in}[i]]}} + \beta$$

Donde γ y β son parámetros entrenables.

Layer Normalization (LayerNorm)

Existen otros tipos de normalización por capas. Por ejemplo, si calculamos la media $\mu = \frac{1}{d} \sum_i^d x_{in}[i]$ y varianza de la capa $\sigma^2 = \frac{1}{d} \sum_i^d (x_{in}[i] - \mu)^2$. A diferencia de BatchNorm, la media y varianza se calculan sobre los elementos $x_{in}[i]$.



Batch GD

Calcula el gradiente usando **todo** el dataset.

- Preciso pero computacionalmente inviable para datasets grandes.

Stochastic GD (SGD)


Calcula el gradiente usando **un solo** dato a la vez.

- + Rápido, eficiente y el ruido ayuda a escapar de mínimos locales.
- Actualizaciones muy ruidosas.

Stochastic GD (SGD)

$$\theta^{k+1} \leftarrow \theta^k - \eta \nabla E(\theta^k)$$

Descenso de Gradiente Estocástico (SGD)



Mini-batch SGD

Calcula el gradiente $\nabla_{\mathcal{B}_k} E(\theta^k)$ sobre un **pequeño lote** $|\mathcal{B}_k| \ll n$ (mini-batch) de datos.

- + Reduce el ruido y aprovecha la computación paralela (multi-GPU).
- + Para modelos grandes, es posible combinar paralelismo de datos y paralelismo de modelos.

Momentum

- ▶ Es una forma de solucionar el problema de valores propios de la matriz Hessiana es agregar un término de **momento**. Ayuda a acelerar en direcciones de baja curvatura y amortiguar oscilaciones .

$$\begin{aligned} \mathbf{v}^k &\leftarrow \beta \mathbf{v}^{k-1} - \eta E(\theta^k), \\ \theta^{k+1} &\leftarrow \theta^k + \mathbf{v}^k \end{aligned}$$

- ▶ **Nesterov**: Modifica el algoritmo de **momento**, utilizando el gradiente en una posición futura proyectada.

$$\mathbf{v}^{k+1} \leftarrow \beta \mathbf{v}^{k-1} - \eta E(\theta^k + \beta \mathbf{v}^k)$$

Algoritmos de Descenso de Gradiente (GD)







Figura: Y. Nesterov, A Method of Solving a Convex Programming Problem with Convergence Rate $O(1/k^2)$, Soviet Mathematics Doklady, vol. 27, no. 2, pp. 543–547, 1983.

Problema Inverso: Dado un conjunto finito de datos, existen infinitos modelos que podrían haberlos generado. ¿Cómo elegimos el correcto?







Alto Sesgo, Baja Varianza



Bajo Sesgo, Alta Varianza



Bajo Sesgo, Baja Varianza (Ideal)



Alto Sesgo, Alta Varianza

Problema Inverso: Dado un conjunto finito de datos, existen infinitos modelos que podrían haberlos generado. ¿Cómo elegimos el correcto?

Sesgo Inductivo (Inductive Bias)

Para generalizar, necesitamos introducir **suposiciones** o **conocimiento previo** sobre la naturaleza de la solución. Esto se llama *sesgo inductivo*.

- ▶ **Teorema de No Free Lunch (Wolpert, 1996)** : Ningún algoritmo es el mejor para todos los problemas. El éxito depende de que el sesgo inductivo del algoritmo coincida con el problema.
- ▶ La regularización es una forma de introducir un sesgo inductivo explícito.

Weight Decay (Regularización L2)

Añade un término de penalización a la pérdida: $E(\theta) + \lambda ||\theta||_2$

- **Sesgo inductivo:** Prefiere funciones "más suaves" (con pesos pequeños)
- Reduce la varianza del modelo a costa de un pequeño aumento en el sesgo

Data Augmentation

Aumenta artificialmente el dataset creando versiones transformadas de los datos (rotaciones, recortes, etc.).

- **Sesgo inductivo:** Enseña explícitamente al modelo a ser invariante a estas transformaciones .
- Extremadamente efectivo y fácil de implementar, especialmente para imágenes.

Dropout

Durante el entrenamiento, "apaga" neuronas aleatoriamente con una probabilidad p .

- Previene la co-adaptación compleja entre neuronas.
- Es una forma eficiente de promediar un número exponencial de redes neuronales distintas (ensemble) .

Early Stopping

Monitoriza el error en un set de validación y detiene el entrenamiento cuando este error deja de mejorar.

- La forma más simple de regularización.
- Controla la complejidad efectiva del modelo, que aumenta con las épocas de entrenamiento.

- ▶ **Descenso del Gradiente** es algoritmo para encontrar un mínimo en la función de pérdida. El **momento** ayuda a controlar el efecto de los puntos silla.
- ▶ **La regularización** es una técnica para asegurar que ese mínimo corresponda a un modelo que generaliza. Se basa en el principio fundamental del *sesgo inductivo*.
- ▶ Las innovaciones modernas como **BatchNorm** y **LayerNorm** son poderosas porque mejoran tanto la optimización (haciendo el entrenamiento más fácil y rápido) como la regularización (llevando a mejores modelos).