Segmentación Semántica

De U-Net a Segment Anything, con aplicación a la retinopatía diabética

Sergio Hernández, PhD
shernandez@ucm.cl



Magíster en Data Science — Universidad Católica del Maule

Hoja de Ruta

Fundamentos

Arquitecturas Clásicas

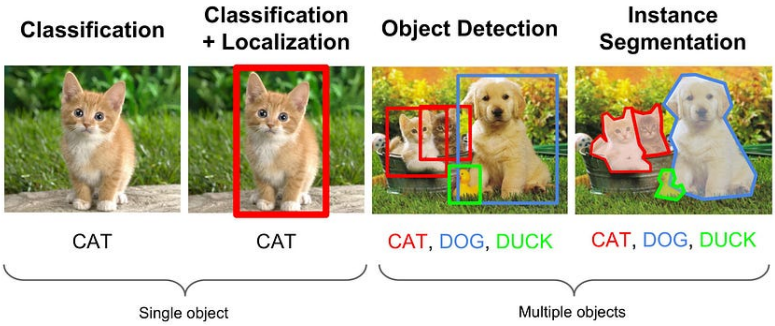
Funciones Objetivo

Segment Anything

Aplicaciones en Oftalmología

Resumen

Segmentación Semántica vs. Clasificación



Clasificación

- Una etiqueta para **la imagen completa**.
- Responde: *¿qué es esto?*
- Salida: clase global y probabilidades.

Segmentación Semántica

- Una etiqueta para **cada pixel**.
- Responde: *¿qué es cada parte?*
- Salida: mapa de etiquetas (alto $\times$ ancho).

Tres Formas de Segmentar una Imagen

$$f : \mathbb{R}^{H \times W \times 3} \to \{1, \ldots, K\}^{H \times W} \qquad \text{(asignar una de } K \text{ clases a cada pixel)}$$

Semántica

Una etiqueta por pixel. Dos personas forman una sola región "persona".
Ej.: FCN, U-Net, DeepLab.

Instancia

Cada objeto de una misma clase recibe su propia máscara.
Ej.: Mask R-CNN.

Panóptica

Une ambas: regiones amorfas (cielo, pista) y objetos contables con identidad.
Ej.: Mask2Former.

Ojo

SAM no hace ninguna de las tres exactamente: produce máscaras **sin clase** a partir de un prompt.

Cómo Medimos una Máscara

IoU (Jaccard)

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|}$$

Penaliza por igual FP y FN. La mIoU promedia por clase.

Dice (F1)

$$\text{Dice} = \frac{2|A \cap B|}{|A| + |B|}$$

Es el F1 por pixel: $\text{Dice} = \frac{2\,\text{IoU}}{1+\text{IoU}}$.

Exactitud de pixel

$$\text{Acc} = \frac{\text{correctos}}{\text{total}}$$

Engañosa con desbalance: si la lesión ocupa menos del 1%, predecir "fondo" en todo da más de 99%.

En video

SAM 2 reporta $\mathcal{J}\&\mathcal{F}$: $\mathcal{J}$ es la IoU de la región y $\mathcal{F}$ la precisión del contorno.

Una Década de Segmentación con Deep Learning



Pregunta guía del bloque

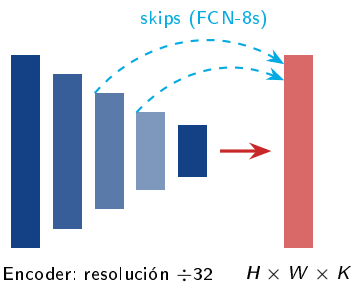
¿Cómo recuperar la resolución espacial sin perder contexto? Cada arquitectura responde de manera distinta.

FCN: Clasificar Cada Pixel

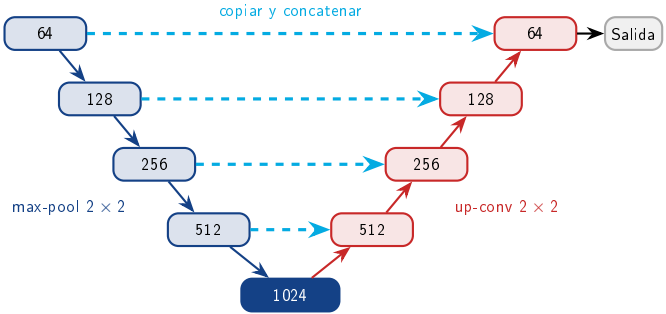
FCN (Long et al., 2015) reutiliza un clasificador de imágenes como clasificador de pixeles.

Tres ideas

- **Convolucionalizar**: las capas densas de VGG se reemplazan por convoluciones 1×1; acepta cualquier tamaño.
- **Sobremuestrear**: convoluciones transpuestas recuperan la resolución que el pooling redujo 32 veces.
- **Saltos**: fusionar capas intermedias (FCN-16s, FCN-8s) devuelve el detalle fino.



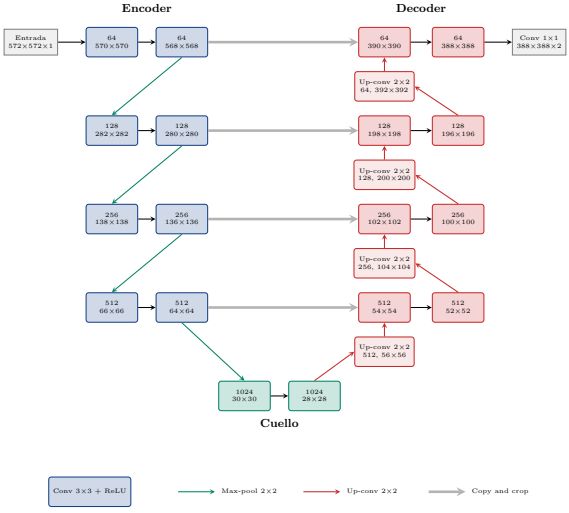
U-Net: Simetría y Conexiones de Salto



Ronneberger et al., 2015

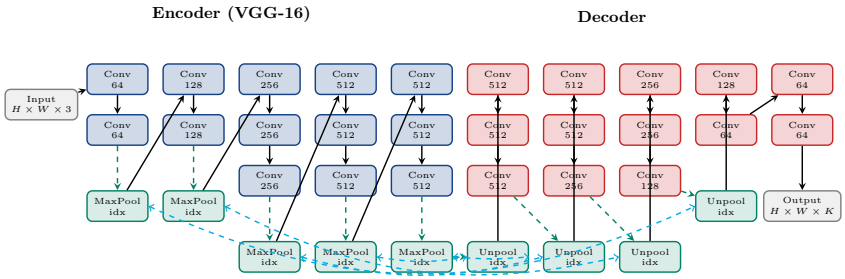
- **Bajada**: conv 3×3 + max-pool; duplica canales, reduce resolución.
- **Subida**: up-conv y concatenación con el mapa del mismo nivel.
- **Por qué perdura**: rinde con pocas imágenes anotadas; sigue siendo la línea base en imagen médica (nnU-Net).

U-Net (2015): Diagrama de la Arquitectura



SegNet: Pooling con Índices

SegNet (Badrinarayanan et al., 2017) almacena solo los índices del max-pooling en el encoder y los reutiliza para el unpooling en el decoder.



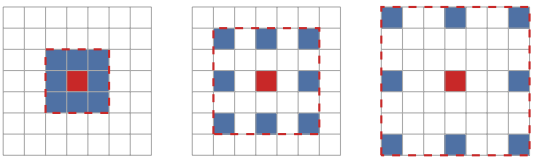
Key Feature: Max-pooling indices stored in encoder, reused in decoder

This preserves spatial structure while reducing parameters vs. U-Net

DeepLab: Más Contexto sin Perder Resolución

DeepLab (Chen et al., 2018) usa convolución atrous (dilatada):

$$y[i] = \sum_k x[i + r \cdot k] \cdot w[k], \qquad \text{un filtro } 3 \times 3 \text{ cubre } (2r+1) \times (2r+1) \text{ pixeles}$$



$r = 1$ $r = 2$ $r = 3$

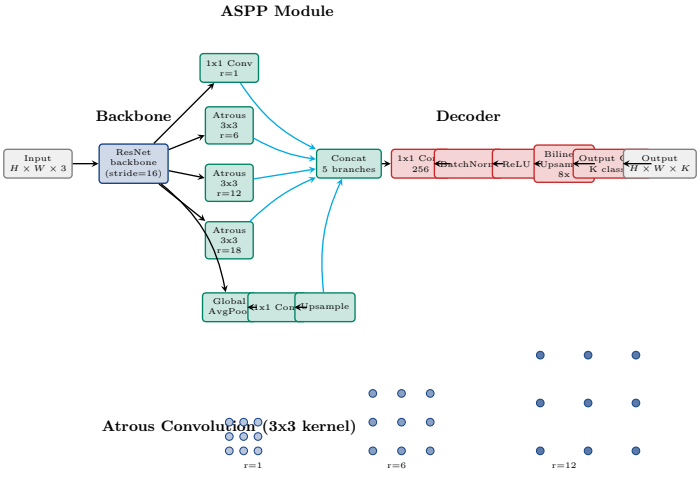
ASPP

Ramas paralelas con $r = 6, 12, 18$ + pooling global, concatenadas: contexto multiescala. **v1–v2** refinaban con un CRF denso; **v3+** usa un decoder con features de bajo nivel.

Ventaja Clave

Mayor receptive field sin parámetros extra ni reducir resolución.

DeepLab: Módulo ASPP



Transformers: de Clasificar Pixeles a Clasificar Máscaras

SETR (2021)

Un ViT como codificador: atención global desde la primera capa, pero costoso en alta resolución.

SegFormer (2021)

Codificador jerárquico multiescala sin codificación posicional fija y un decoder MLP ligero.

Mask2Former (2022)

Predice N máscaras, cada una con su clase, mediante atención enmascarada. Un modelo para las tres tareas.

Conexión con SAM

SAM hereda esta idea: su decodificador produce **máscaras**, no un mapa de clases.

Pérdidas por Pixel: Cross-Entropy y Variantes

Entropía cruzada (CE)

$$\mathcal{L}_{\mathsf{CE}} = -\frac{1}{N}\sum_{i}\sum_{c} y_{ic}\log p_{ic}$$

Cada pixel es una clasificación independiente; la clase mayoritaria domina el gradiente.

CE ponderada

$$\mathcal{L}_{\mathsf{wCE}} = -\frac{1}{N}\sum_{i}\sum_{c} w_c\, y_{ic}\log p_{ic}$$

$w_c \propto 1/\text{frecuencia}$. Compensa el desbalance, pero puede volver ruidoso el entrenamiento.

Focal (Lin et al., 2017)

$$\mathcal{L}_{\mathsf{FL}} = -\alpha\,(1-p_t)^{\gamma}\log p_t$$

Reduce el peso de los pixeles fáciles; $\gamma = 2$ es lo habitual.

Pérdidas por Región: Optimizar el Solapamiento

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2\sum_i p_i g_i + \varepsilon}{\sum_i p_i + \sum_i g_i + \varepsilon} \qquad \text{(Milletari et al., 2016)}$$

Tversky (Salehi et al., 2017)

$$\text{TI} = \frac{\text{TP}}{\text{TP} + \alpha\,\text{FP} + \beta\,\text{FN}}$$

Con $\beta > \alpha$ castiga más los falsos negativos. Con $\alpha = \beta = 0{,}5$ recupera Dice.

Combinada

$$\mathcal{L} = \lambda_1 \mathcal{L}_{\text{Focal}} + \lambda_2 \mathcal{L}_{\text{Dice}}$$

Gradientes estables por pixel + objetivo de solapamiento.

Dato de SAM 2

SAM 2 combina focal y Dice en razón 20:1 (más MAE para la IoU predicha y CE para la oclusión).

¿Qué Pérdida Usar?

Situación	Pérdida sugerida	Por qué
Clases balanceadas, objetos grandes	Entropía cruzada	Simple y con gradientes estables
Desbalance moderado	CE ponderada	Sube el peso de las clases raras
Objetos pequeños o raros	Dice + Focal	Solapamiento sin ahogarse en el fondo
Cribado: no omitir lesiones	Tversky ($\beta > \alpha$)	Prioriza la sensibilidad
Los bordes importan	Boundary loss o Lovász	Supervisa el contorno u optimiza la IoU

Estrategia Práctica

Empezar con CE (o Focal) + Dice y ajustar solo si la métrica de interés lo pide. En retinopatía diabética estamos en la fila de objetos pequeños y raros.

Segment Anything: un Modelo para Cualquier Objeto

SAM (Kirillov et al., 2023) define una tarea general, la **segmentación por prompts**, y un modelo que la resuelve en cero disparos.

11 M
imágenes en el dataset SA-1B

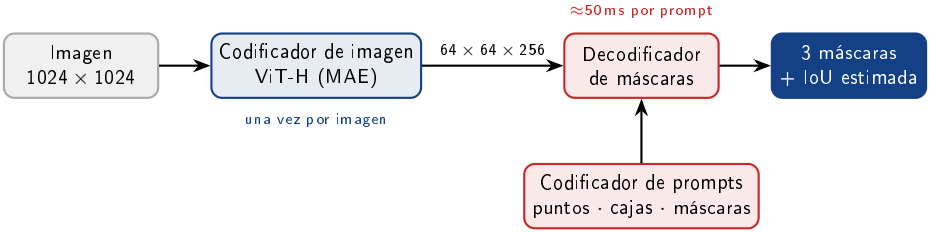
1,1 B
máscaras, anotadas con el modelo en el ciclo

3
tipos de prompt: puntos, cajas y máscaras

Data engine

El modelo ayuda a anotar, los datos mejoran el modelo, y así iterativamente. SAM **no asigna clases**: devuelve la máscara de lo que el usuario señala.

SAM: Codificar una Vez, Decodificar Muchas



Pesado, una vez

El ViT-H, preentrenado con MAE, se ejecuta una sola vez por imagen.

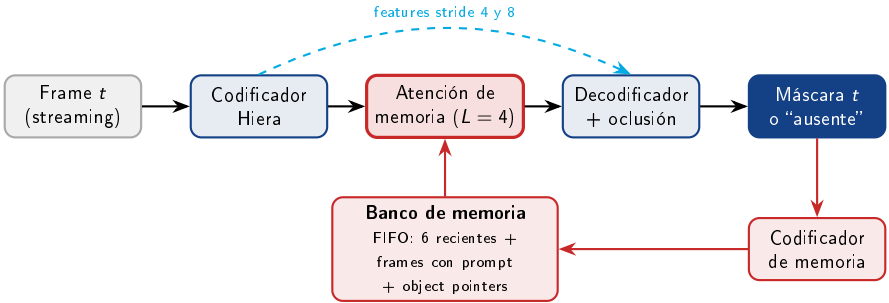
Ligero, muchas veces

Cada prompt toma unos 50 ms en el navegador: interacción en tiempo real.

Ambigüedad

Un clic puede indicar parte, objeto o conjunto: entrega 3 máscaras con su IoU.

SAM 2: Memoria para Segmentar Video



Ravi et al., Meta FAIR

Una imagen es un video de un solo frame: con la memoria vacía, SAM 2 se comporta como SAM. Un clic de corrección en cualquier frame se propaga gracias a la memoria.

Lo que Aporta SAM 2, en Cifras

6×
más rápido que SAM en imágenes y más preciso: 58,9 vs 58,1 mIoU (1 clic, 23 datasets)

3×
menos interacciones que SAM + XMem++ o SAM + Cutie en video

53×
más máscaras que cualquier dataset VOS previo: SA-V tiene 35,5 M en 50,9 K videos

76,8
$\mathcal{J}\&\mathcal{F}$ en SA-V val vs 61,4 del mejor método previo; 43,8 FPS en una A100

Data engine

Con SAM 2 en el ciclo, anotar tomó 4,5 s por frame frente a 37,8 s con SAM frame a frame: 8,4× más rápido.

Fuente: Ravi et al., *SAM 2: Segment Anything in Images and Videos*, Meta FAIR. Resultados de SAM 2.1, Hiera-B+.

De SAM a MedSAM: Cerrar la Brecha de Dominio

Por qué SAM no basta

- Entrenado con fotos naturales: bordes difusos y bajo contraste lo confunden.
- Máscaras sin clase: no sabe qué es una hemorragia.
- Cada token resume 16×16 px: las lesiones diminutas se diluyen.

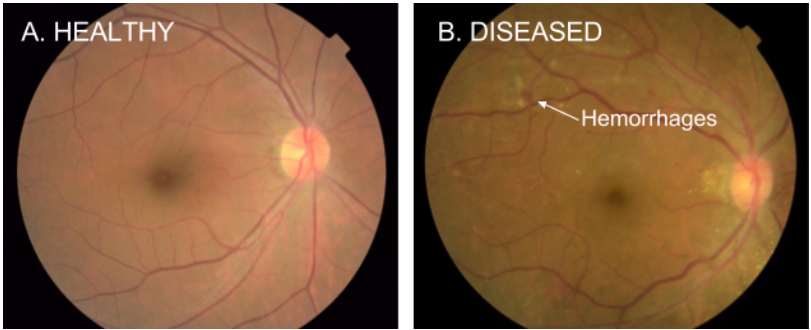
MedSAM (Nat. Commun., 2024)

SAM ajustado con 1.570.263 pares imagen-máscara de 10 modalidades y más de 30 tipos de cáncer. Evaluado en 86 tareas internas y 60 externas, supera a especialistas por modalidad.

MedSAM2 (2025)

Parte de SAM 2.1; ajustado con más de 455.000 pares 3D y 76.000 frames de video (TC, RM, PET, ecografía, endoscopía). Reduce más de 85% el costo de anotación manual.

Retinopatía Diabética: el Fondo de Ojo



La **retinopatía diabética (RD)** es una de las principales causas de ceguera prevenible en adultos en edad laboral.

Signos visibles

Microaneurismas, hemorragias, exudados duros y blandos; en etapas avanzadas, neovascularización.

Desafío

Lesiones pequeñas y dispersas, revisión experta y cribado de poblaciones masivas.

Retinopatía Diabética en Cifras

22,3%

de las personas con diabetes tiene retinopatía

160,5 M

adultos con RD proyectados para 2045

Teo et al., *Ophthalmology*, 2021.

Microaneurismas

MA. Dilataciones capilares; el primer signo. Miden pocos pixeles.

Exudados duros

EX. Depósitos de lípidos amarillos, de bordes nítidos.

Hemorragias

HE. Sangrado intrarretiniano: manchas rojas puntiformes o en llama.

Exudados blandos

SE. Manchas algodonosas por isquemia; blanquecinas y difusas.

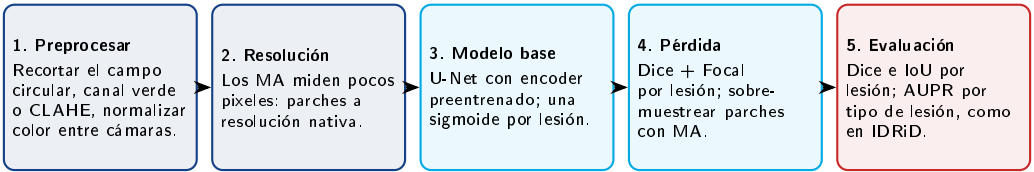
Datos Públicos con Máscaras por Lesión

Dataset	Imágenes con máscara	Anotación	Detalle
IDRiD (2018)	81 (54 entrenamiento, 27 prueba)	MA, HE, EX, SE y disco óptico	4288×2848 px, India; 516 imágenes con grado de RD y edema macular
DDR	757, de 13.673 imágenes	MA, HE, EX, SE	Grados de RD (escala internacional) + no gradable
FGADR	1.842	Lesiones a nivel de pixel + grado	Incluye casos proliferativos
Refined IDRiD (2026)	81, a 1024×1024	7 lesiones + 4 estructuras anatómicas	Revisado por oftalmólogos; agrega neovascularización, hemorragia vítrea e IRMA

Desbalance

Exudados duros y hemorragias concentran la mayoría de los pixeles de lesión; los MA son escasos y diminutos.

Un Flujo Base para Segmentar Lesiones



Baseline

Este flujo es la vara con la que se mide cualquier enfoque basado en SAM.

Tres Maneras de Usar SAM en el Fondo de Ojo

1. Prompts desde la mirada

GlanceSeg (Jiang et al.)

El mapa de mirada del oftalmólogo ubica la zona; un mapa de saliencia genera puntos-prompt para SAM y un filtro de conocimiento médico depura los MA, en tiempo real.

2. Ajuste eficiente + texto

TP-DRSeg (MICCAI 2024)

Describe cada lesión con texto explícito y lo inyecta en el codificador de SAM con ajuste eficiente de parámetros. Obtiene máscaras con clase.

3. Anotación asistida

Idea del data engine de SAM 2

SAM o MedSAM aceleran el etiquetado y el experto corrige. Las máscaras entrenan un U-Net especializado y barato de ejecutar.

Desafíos Abiertos

Lesiones diminutas

Embedding de 64×64: cada token cubre 16×16 px. SAM 2 suma features de stride 4 y 8 al decoder, pero los MA siguen al límite.

Desbalance extremo

Casi todo es fondo: Dice y Focal ayudan; evaluar por tipo de lesión.

Cambio de dominio

Cámaras, poblaciones y protocolos distintos: validar siempre en un dataset externo.

Calidad del ground truth

Bordes difusos en exudados blandos y hemorragias. En IDRiD las máscaras las trazó un estudiante entrenado por oftalmólogos; la versión refinada corrige errores.

Del pixel a la decisión clínica

La máscara debe traducirse en un grado de RD y una derivación, con validación prospectiva y aprobación regulatoria.

Actividad Práctica: U-Net vs. SAM en IDRiD

1. Entrenar un U-Net para **exudados duros**, primero con BCE y luego con Dice + Focal. Comparar Dice y AUPR en las 27 imágenes de prueba.

2. Evaluar **SAM o MedSAM** sin ajuste, con cajas derivadas del ground truth y con 1, 3 y 5 clics por lesión.

3. Discutir: ¿cuántos clics necesita SAM para igualar al U-Net? ¿En qué lesiones falla y por qué?

Entregable

Notebook `labs/2.6.2_SegmentacionRetinopatiaSAM.ipynb` + informe breve con una tabla de métricas por lesión y método.

Conclusiones

- **Fundamentos:** segmentar es clasificar cada pixel; medir con Dice e IoU, nunca solo exactitud.
- **Arquitecturas:** U-Net (datos pequeños), DeepLab (contexto multiescala), transformers (clasificación de máscaras).
- **Funciones objetivo:** combinar CE o Focal + Dice; Tversky si la sensibilidad manda.
- **SAM / SAM 2:** segmentación por prompts sin clases; SAM 2 agrega memoria para video.
- **Retinopatía diabética:** lesiones diminutas y desbalanceadas; SAM sirve mejor adaptado o como herramienta de anotación.

Referencias

Arquitecturas y pérdidas

Long et al. (2015). FCN. *CVPR*.
Ronneberger et al. (2015). U-Net. *MICCAI*.
Badrinarayanan et al. (2017). SegNet. *TPAMI*.
Milletari et al. (2016). V-Net (Dice loss). *3DV*.
Zhao et al. (2017). PSPNet. *CVPR*.
He et al. (2017). Mask R-CNN. *ICCV*.
Lin et al. (2017). Focal loss. *ICCV*.
Salehi et al. (2017). Tversky loss. *MLMI*.
Chen et al. (2018). DeepLabv3+. *ECCV*.
Berman et al. (2018). Lovász-Softmax. *CVPR*.
Kervadec et al. (2019). Boundary loss. *MIDL*.
Xie et al. (2021). SegFormer. *NeurIPS*.
Cheng et al. (2022). Mask2Former. *CVPR*.

SAM y medicina

Kirillov et al. (2023). Segment Anything. *ICCV*.
Ravi et al. (2025). SAM 2. *ICLR*.
Ma et al. (2024). MedSAM. *Nat. Commun.* 15:654.
Ma et al. (2025). MedSAM2. arXiv:2504.03600.
Teo et al. (2021). Prevalencia global de RD. *Ophthalmology*.
Porwal et al. (2018). IDRiD. *Data* 3(3):25.
Li et al. (2019). DDR. *Information Sciences*.
Jiang et al. (2023). GlanceSeg. arXiv:2311.08075.
TP-DRSeg (2024). *MICCAI*. github.com/wxliii/TP-DRSeg