

Heads de detección multi-escala

conv 3×3 por feature map: $m \times m \times (\#anchors \times (4 + 20 \text{ clases}))$

