

Estudio de casos

Aprendizaje profundo en la detección de riesgo materno

MDS221 — Inteligencia Artificial • Unidad 1
Magíster en Data Science — Universidad Católica del Maule
Sergio Hernández, PhD • shernandez@ucm.cl

Modalidad	Individual.
Dedicación	Aproximadamente 12 horas de trabajo autónomo.
Entregables	Notebook reproducible <code>.ipynb</code> + informe en PDF (6–8 páginas).
Evaluación	Rúbrica de la sección 6 (240 puntos, 60 % de exigencia).

El caso en una frase. Un artículo publicado en *Healthcare* (2025) compara seis clasificadores para predecir el nivel de riesgo de una embarazada a partir de seis signos vitales. El **bosque aleatorio alcanza 84,5 %** de exactitud; las **redes neuronales se quedan en 69 %**. La sobreparametrización y la profundidad son justamente lo que hace funcionar al aprendizaje profundo. **¿Por qué aquí pierde?**

1. Contexto clínico

La mortalidad materna sigue siendo uno de los indicadores de salud más sensibles a la desigualdad: la mayoría de las muertes ocurre en contextos con acceso tardío o intermitente al control prenatal, y una fracción importante es evitable si el riesgo se detecta a tiempo. En ese escenario, un sistema de *triage* que priorice a quién derivar — construido sobre mediciones baratas y repetibles (presión, glicemia, temperatura, pulso) — tiene un valor clínico directo, incluso si su exactitud es modesta.

Tzimourta et al. (2025) exploran precisamente eso: entrenan seis clasificadores sobre registros recolectados mediante un sistema de monitoreo IoT en hospitales, clínicas comunitarias y centros de salud materna de Bangladesh, y comparan su desempeño para clasificar el riesgo en tres niveles.

2. El conjunto de datos

Maternal Health Risk — UCI Machine Learning Repository, id 863. DOI 10.24432/C5DP5D, licencia CC BY 4.0.

<https://archive.ics.uci.edu/dataset/863/maternal+health+risk>

Variable	Unidad	Descripción
Age	años	Edad de la gestante.
SystolicBP	mmHg	Presión arterial sistólica.
DiastolicBP	mmHg	Presión arterial diastólica.
BS	mmol/L	Glicemia (<i>blood sugar</i>).
BodyTemp	°F	Temperatura corporal.
HeartRate	lpm	Frecuencia cardíaca en reposo.
RiskLevel	—	Objetivo: <i>low risk</i> (406), <i>mid risk</i> (336), <i>high risk</i> (272).

Seis atributos, tres clases, y del orden de mil registros. Se descarga con:

```
from ucimlrepo import fetch_ucirepo
mhr = fetch_ucirepo(id=863)
X, y = mhr.data.features, mhr.data.targets
```

3. Línea Base

Los autores entrenan con validación cruzada de 10 pliegues y reportan:

Clasificador	Exactitud	Precisión	Sensibilidad (TP rate)
Naïve Bayes	59,07 %	58,10 %	59,10 %
Perceptrón multicapa (MLP)	69,03 %	61,04 %	61,01 %
Red totalmente conectada (FCNN)	68,93 %	68,96 %	68,91 %
Máquina de soporte vectorial	75,74 %	76,30 %	75,70 %
Árbol de decisión	78,60 %	79,00 %	78,60 %
Bosque aleatorio	84,52 %	84,93 %	84,52 %
Bosque aleatorio + SMOTE	88,03 %	88,10 %	88,00 %

Las dos arquitecturas neuronales quedan **últimas entre los métodos no triviales**, quince puntos por debajo del bosque. Ese es el hecho a explicar. Los mecanismos que explican el desempeño del Aprendizaje Profundo son : sobreparametrización, umbral de interpolación, doble descenso, planitud del mínimo, sesgo inductivo, billete de lotería. El trabajo consiste en **usar ese vocabulario como instrumento de medición**, no como decorado.

Pregunta central del caso. ¿El fracaso relativo de las redes neuronales en este problema es (a) un problema de *capacidad* — faltan parámetros o datos —, (b) un problema de *optimización* — la solución existe pero el entrenamiento no la encuentra —, o (c) un problema de *sesgo inductivo* — la arquitectura no encaja con la estructura del dato? Su informe debe defender una respuesta **con evidencia propia**, no con citas.

4. Tareas

Cada tarea indica con qué parte de la clase 1.4 se conecta. Todos los experimentos se reportan con **al menos 5 semillas** y con media $\pm$ desviación estándar: una diferencia de dos puntos sin barras de error no es un resultado.

T1 — Línea base y auditoría del dato

1. Reproduzca la línea base: bosque aleatorio y MLP con validación cruzada estratificada de 10 pliegues. Compare sus números con la tabla anterior y explique cualquier brecha mayor a 3 puntos.
2. Cuente las filas duplicadas exactas. Reevalúe asegurando que **ningún duplicado quede a ambos lados** de la partición. ¿Cuánta exactitud se pierde? Discuta qué parte del 84,5 % original era memorización medida sobre sí misma.
3. Con clases 406/336/272, argumente por qué la exactitud sola es un mal resumen. Reporte matriz de confusión y F1 por clase.

T2 — Generalización y sobreparametrización

1. Permute `RiskLevel` al azar, destruyendo toda relación con las variables. Entrene MLP de ancho creciente hasta llevar el error de **entrenamiento** a cero.
2. Reporte el número mínimo de parámetros necesario y compárelo con $n \approx 1000$ ejemplos. ¿Cuántas veces sobreparametrizado quedó el modelo?
3. Repita con las etiquetas reales. ¿Necesita más o menos capacidad? ¿Qué dice eso sobre la “simplicidad” de la función subyacente?

T3 — Dilema Sesgo-Varianza

1. MLP de una capa oculta con ancho en escala logarítmica, de 2 a 2048 unidades. Grafique error de entrenamiento y de prueba contra número de parámetros.
2. Marque el **umbral de interpolación** (parámetros $\approx$ datos). ¿Observa el pico y el segundo descenso, o solo la curva en U clásica?
3. Qué condiciones no se cumplen aquí (tamaño de n , ruido de etiqueta, regularización implícita del optimizador).

T4 — Hiperparámetros

1. Grilla de tamaño de lote $\in \{8, 32, 128, 512\}$ por tasa de aprendizaje $\in \{10^{-3}, 10^{-2}, 10^{-1}\}$. Grafique el error de prueba contra la **razón lote/tasa**.
2. Estime la planitud de cada mínimo: pérdida máxima en una vecindad $\|\delta\| = \varepsilon$ alrededor de los parámetros finales (criterio de Keskar), con al menos 20 direcciones aleatorias.
3. ¿Correlacionan planitud y generalización **en este problema**? Contraste su resultado con la advertencia de Dinh et al. sobre reparametrizaciones triviales de ReLU.

T5 — Sesgo inductivo

1. Formule una hipótesis concreta sobre por qué un *ensemble* de árboles supera a una red en datos tabulares pequeños, y diseñe **un experimento que pueda refutarla**.
2. Contraprueba obligatoria: intente cerrar la brecha con al menos dos intervenciones (normalización por variable, regularización fuerte, *early stopping*, *embeddings* de variables discretizadas, *ensemble* de redes). Reporte cuánto se acorta.
3. Relacione su conclusión con las tres explicaciones que la clase da para la profundidad: complejidad de la función, tratabilidad del entrenamiento y sesgo inductivo.

T6 — Modelos Fundacionales

1. Utilice el modelo fundacional TabFM¹ para resolver el problema de clasificación usando promediado de logits (logit averaging).
2. Utilice el modelo fundacional TabFM para resolver el problema de clasificación usando feature engineering (feature crosses / SVD features + NNLS-weighted blending + probability calibration).
3. Compare los resultados de ambos enfoques con respecto a las métricas de evaluación ROC, AUC y log-loss con respecto al mejor MLP obtenido.

```
model = tabfm.tabfm_v1_0_0_pytorch.load(model_type="classification")
results = {}
results["default"] = _evaluate(
    tabfm.TabFMClassifier(model=model, random_state=SEED),
    x_train, y_train, x_test, y_test,
)
results["ensemble"] = _evaluate(
    tabfm.TabFMClassifier.ensemble(model=model, random_state=SEED),
    x_train, y_train, x_test, y_test,
)
```

¹https://github.com/google-research/tabfm/blob/main/examples/tabarena_classification_example.py

T7 — Lectura clínica: el error que no cuesta lo mismo

1. Un falso negativo de *high risk* y un falso positivo de *low risk* no son equivalentes. Proponga una matriz de costos justificada clínicamente y reevalúe **todos** los modelos bajo ese criterio. ¿Cambia el ranking?
2. Reporte explícitamente la sensibilidad de la clase *high risk* y ajuste umbrales o pesos de clase para maximizarla a costo controlado.
3. Robustez: perturbe las señales $\pm 5\%$ (error plausible de un tensiómetro o un termómetro) y mida la caída de desempeño de cada modelo. Discuta la analogía con los ejemplos adversarios de la clase: ¿qué tan lejos de la variedad de datos hay que ir para romper la predicción?
4. Los datos provienen de centros de salud de Bangladesh mediante sensores IoT. Discuta qué supuestos habría que revisar antes de siquiera considerar un despliegue en la red asistencial chilena.

5. Entregables

1. **Notebook reproducible** (.ipynb). Debe correr de principio a fin sin intervención manual, con semillas fijadas y la descarga del dato incluida. Un cuaderno que no corre se evalúa como si no se hubiera entregado.
2. **Informe** en PDF, 6 a 8 páginas, con esta estructura mínima:
 - Auditoría del dato y línea base corregida (T1).
 - Resultados de T2–T5, cada uno con su figura y su lectura.
 - Su respuesta a la pregunta central: (a) capacidad, (b) optimización o (c) sesgo inductivo — **y por qué descarta las otras dos**.
 - Sección clínica y ética (T7).
 - Una sección final de **límites**: qué no logró establecer y qué experimento habría hecho falta.
3. **Tabla resumen** de una página con todos los modelos entrenados: arquitectura, número de parámetros, protocolo, métrica, media $\pm$ desviación.

Sobre el uso de asistentes de IA. Está permitido y se espera que lo declaren: incluyan un párrafo indicando qué herramienta usaron y para qué. Lo que se evalúa es el criterio con que interpretan los resultados, y eso no se delega. Un informe con conclusiones que el propio cuaderno no respalda se penaliza en *Precisión y rigor*, independientemente de quién lo haya escrito.

Un resultado negativo bien establecido vale tanto como uno positivo. Si tras un barrido honesto la red sigue perdiendo contra el bosque, esa *es* la conclusión: la sobreparametrización ayuda a la escala y complejidad de los conjuntos que se usan hoy en visión y lenguaje, no que una red gane siempre.

6. Rúbrica de evaluación

Seis criterios, cuatro niveles. Puntaje máximo **240 puntos**.

Aspecto	Excelente (40)	Bueno (30)	Aceptable (20)	Bajo (10)
Reproducción y rigor experimental	Reproduce la línea base, detecta y trata los duplicados, y todo resultado viene con semillas múltiples y dispersión. El cuaderno corre completo.	Reproduce la línea base con un protocolo correcto; la auditoría del dato o la repetición con semillas es parcial.	Reproduce resultados pero con un protocolo discutible (fuga posible, una sola semilla, métrica única).	No reproduce la línea base o el cuaderno no corre; las cifras no son verificables.
Diseño de los experimentos	Los barridos de T2–T5 están bien diseñados, con rangos justificados y controles que permiten aislar la causa.	Los experimentos son correctos pero alguno tiene rango insuficiente o le falta un control.	Ejecuta los experimentos mínimos sin justificar las decisiones de diseño.	Los experimentos no permiten concluir nada: rangos arbitrarios, sin controles, o incompletos.
Interpretación teórica (cap. 20)	Usa los conceptos de la clase como instrumento de medición; distingue con evidencia entre capacidad, optimización y sesgo inductivo, y reconoce lo que sus datos <i>no</i> permiten afirmar.	Aplica los conceptos correctamente y defiende una tesis, con alguna afirmación que excede la evidencia.	Menciona los conceptos correctos pero la conexión con sus propios resultados es débil o decorativa.	Usa el vocabulario de forma errónea o repite las conclusiones del artículo sin contrastarlas.
Análisis de datos y evidencia	Análisis profundo: figuras legibles y bien elegidas, incertidumbre reportada, comparaciones justas entre modelos.	Análisis sólido; las figuras comunican, con mejoras posibles en claridad o en el tratamiento de la incertidumbre.	Análisis adecuado pero superficial; faltan métricas por clase o las figuras no aportan al argumento.	Análisis superficial o inconsistente con las cifras del cuaderno.
Comunicación del informe	Preciso, bien estructurado y sin errores; cada afirmación es rastreable hasta una figura o tabla.	Bien organizado, con pocos errores menores.	Se entiende, pero la estructura o la redacción dificultan seguir el argumento.	Desorganizado, impreciso o con errores graves que impiden la comprensión.
Lectura clínica y ética	Trata el costo asimétrico del error con una matriz justificada, reevalúa bajo ese criterio y discute con seriedad los límites de transferir el modelo a otro sistema de salud.	Aborda el costo asimétrico y los límites del despliegue, con menos profundidad o sin reevaluar los modelos.	Menciona el problema ético de forma genérica, sin consecuencias sobre el análisis.	Omite la dimensión clínica o la reduce a una frase de cierre.

Conversión a nota (60 % de exigencia, P = puntaje sobre 240):

$$\text{Nota} = \begin{cases} 1,0 + 3,0 \frac{P}{144} & \text{si } P < 144, \\ 4,0 + 3,0 \frac{P - 144}{96} & \text{si } P \geq 144. \end{cases}$$

Puntaje	48	96	120	144	168	192	216	240
Nota	2,0	3,0	3,5	4,0	4,75	5,5	6,25	7,0

7. Referencias

- Tzimourta, K. D., Tsiouras, M. G., Angelidis, P., Tsalikakis, D. G. & Orovou, E. (2025). *Maternal Health Risk Detection: Advancing Midwifery with Artificial Intelligence*. Healthcare, 13(7), 833. <https://doi.org/10.3390/healthcare13070833>
- Ahmed, M. (2023). *Maternal Health Risk* [conjunto de datos]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5DP5D>

- Prince, S. J. D. *Understanding Deep Learning*, capítulo 20 (*Why does deep learning work?*) y capítulo 8 (doble descenso). MIT Press.
<https://udlbook.github.io/udlbook/>
- Zhang, C., Bengio, S., Hardt, M., Recht, B. & Vinyals, O. (2017). *Understanding deep learning requires rethinking generalization*. ICLR.
- Frankle, J. & Carbin, M. (2019). *The lottery ticket hypothesis: finding sparse, trainable neural networks*. ICLR.
- Keskar, N. S., Mudigere, D., Nocedal, J., Smelyanskiy, M. & Tang, P. T. P. (2017). *On large-batch training for deep learning: generalization gap and sharp minima*. ICLR.
- Grinsztajn, L., Oyallon, E. & Varoquaux, G. (2022). *Why do tree-based models still outperform deep learning on typical tabular data?* NeurIPS Datasets and Benchmarks.

Material del curso MDS221, Magíster en Data Science, Universidad Católica del Maule. El conjunto de datos se distribuye bajo licencia CC BY 4.0 y el artículo de referencia bajo CC BY.