

Introducción a la Inteligencia Artificial

Qué es, de dónde viene y en qué punto está (AI Index 2026)

Sergio Hernández, PhD
shernandez@ucm.cl

IA



Magíster en Data Science — Universidad Católica del Maule

1. ¿Qué es la inteligencia artificial?
2. Una breve historia (y sus inviernos)
3. Dos paradigmas: símbolos y conexiones
4. Aprendizaje automático: la idea central
5. El estado del arte según el *AI Index 2026*
6. Riesgos, ética y sostenibilidad
7. Cierre y lecturas

Objetivo de la clase

Construir un mapa conceptual del campo y una **línea base empírica** de sus capacidades actuales, que servirá de referencia para el resto del curso.

¿Qué es la inteligencia artificial?

Definición conceptual

La Inteligencia Artificial (IA) es la rama de la computación dedicada a construir **agentes inteligentes**: sistemas que perciben su entorno, razonan sobre él y actúan para alcanzar objetivos.

¿Qué es la inteligencia artificial?

Definición conceptual

La Inteligencia Artificial (IA) es la rama de la computación dedicada a construir **agentes inteligentes**: sistemas que perciben su entorno, razonan sobre él y actúan para alcanzar objetivos.

“Es la ciencia e ingeniería de hacer máquinas inteligentes, especialmente programas de computador inteligentes.”

— John McCarthy, 1956

¿Qué es la inteligencia artificial?

Definición conceptual

La Inteligencia Artificial (IA) es la rama de la computación dedicada a construir **agentes inteligentes**: sistemas que perciben su entorno, razonan sobre él y actúan para alcanzar objetivos.

“Es la ciencia e ingeniería de hacer máquinas inteligentes, especialmente programas de computador inteligentes.”

— John McCarthy, 1956

Ojo: no hay una definición única. La definición que se adopte determina **qué se mide** y, por lo tanto, cuándo se declara el éxito.

Cuatro definiciones clásicas (Russell & Norvig)

	Como humanos	Racionalmente
Pensar	Modelar la cognición humana	Leyes del pensamiento (lógica)
Actuar	Prueba de Turing	Agente racional

- **Pensar como humano:** ciencia cognitiva; el objetivo es *explicar* la mente.

Cuatro definiciones clásicas (Russell & Norvig)

	Como humanos	Racionalmente
Pensar	Modelar la cognición humana	Leyes del pensamiento (lógica)
Actuar	Prueba de Turing	Agente racional

- ▶ **Pensar como humano:** ciencia cognitiva; el objetivo es *explicar* la mente.
- ▶ **Pensar racionalmente:** lógica formal; correcto pero frágil ante la incertidumbre.

Cuatro definiciones clásicas (Russell & Norvig)

	Como humanos	Racionalmente
Pensar	Modelar la cognición humana	Leyes del pensamiento (lógica)
Actuar	Prueba de Turing	Agente racional

- ▶ **Pensar como humano:** ciencia cognitiva; el objetivo es *explicar* la mente.
- ▶ **Pensar racionalmente:** lógica formal; correcto pero frágil ante la incertidumbre.
- ▶ **Actuar como humano:** imitación; es lo que mide la prueba de Turing.


Cuatro definiciones clásicas (Russell & Norvig)

	Como humanos	Racionalmente
Pensar	Modelar la cognición humana	Leyes del pensamiento (lógica)
Actuar	Prueba de Turing	Agente racional

- ▶ **Pensar como humano:** ciencia cognitiva; el objetivo es *explicar* la mente.
- ▶ **Pensar racionalmente:** lógica formal; correcto pero frágil ante la incertidumbre.
- ▶ **Actuar como humano:** imitación; es lo que mide la prueba de Turing.
- ▶ **Actuar racionalmente:** hacer *lo mejor posible* dada la información disponible. Es el enfoque dominante hoy, y el que adoptaremos en el curso: es medible y no exige imitar a nadie.

IA, aprendizaje automático, aprendizaje profundo

- ▶ **IA:** el campo completo, incluidas la búsqueda, la lógica y la planificación.
- ▶ **Machine Learning (ML):** subcampo donde el comportamiento se *aprende de los datos* en vez de programarse.
- ▶ **Deep Learning (DL):** ML con redes neuronales de muchas capas que aprenden sus propias representaciones.
- ▶ **IA generativa:** modelos que aprenden a *muestrear* de la distribución de los datos (texto, imagen, audio).



Toda la IA generativa es aprendizaje profundo, pero **no** toda la IA es aprendizaje automático.

IA estrecha vs. IA general (AGI)

IA estrecha (*narrow*)

- ▶ Es toda la IA que existe hoy.
- ▶ Entrenada para una **familia acotada** de tareas.
- ▶ Reconocimiento facial, traducción, recomendación, asistentes.
- ▶ Rendimiento sobrehumano en algunas tareas y frágil fuera de su dominio.

IA general (AGI)

- ▶ Competencia amplia al nivel humano en **tareas nuevas**.
- ▶ No existe una definición operativa aceptada, ni una prueba consensuada.
- ▶ Cuidado: los modelos actuales combinan capacidad muy alta con fallos elementales (lo veremos con datos).




La prueba de Turing: ¿pueden pensar las máquinas?

Propuesta por Alan Turing en 1950 como sustituto *operacional* de una pregunta que consideraba mal planteada.

El juego de la imitación

Un interrogador humano (C) conversa por texto con un humano (B) y una máquina (A). Si C no logra distinguir de forma consistente quién es quién, la máquina supera la prueba.




La prueba de Turing: ¿pueden pensar las máquinas?

Propuesta por Alan Turing en 1950 como sustituto *operacional* de una pregunta que consideraba mal planteada.


El juego de la imitación

Un interrogador humano (C) conversa por texto con un humano (B) y una máquina (A). Si C no logra distinguir de forma consistente quién es quién, la máquina supera la prueba.

Crítica moderna: mide la capacidad de *imitar*, no de razonar. Por eso hoy se evalúa con *benchmarks* de tareas concretas y con comparaciones ciegas entre modelos (*arenas*).



Setenta años en una lámina



- ▶ El campo avanza **a saltos**: cada ola nace de una idea algorítmica que se vuelve viable gracias al hardware y a los datos disponibles.
- ▶ Las dos últimas décadas son la excepción: crecimiento sostenido, sin invierno intermedio.

Épocas de optimismo

- ▶ **1950–70:** fundación, lógica simbólica y grandes promesas.
- ▶ **1980s:** auge industrial de los sistemas expertos.
- ▶ **2012–hoy:** datos masivos, GPUs y aprendizaje profundo.

Los inviernos

- ▶ **1974–80 y 1987–93:** recortes de financiamiento y pérdida de interés.
- ▶ Causas: promesas excesivas, límites de cómputo y de datos, costo de mantener sistemas basados en reglas.

Lección para este curso

Distinguir siempre entre lo que un sistema **demuestra** en una evaluación y lo que se **afirma** sobre él. Gran parte de esta clase consiste en aprender a leer evidencia.

¿Qué cambió en la última década?

Datos

De miles a **decenas de billones** de tokens de entrenamiento. La web como corpus.

Cómputo

GPUs y aceleradores dedicados; órdenes de magnitud más de cómputo por modelo.

Algoritmos

Retropropagación a escala, *transformers*, aprendizaje auto-supervisado y por refuerzo.

¿Qué cambió en la última década?

Datos

De miles a **decenas de billones** de tokens de entrenamiento. La web como corpus.

Cómputo

GPUs y aceleradores dedicados; órdenes de magnitud más de cómputo por modelo.

Algoritmos

Retropropagación a escala, *transformers*, aprendizaje auto-supervisado y por refuerzo.

- ▶ Ninguno de los tres factores basta por sí solo: el *transformer* (2017) es un algoritmo, pero solo rinde con datos y cómputo a escala.
- ▶ Consecuencia económica: en 2025, la **industria** produjo más del 90% de los modelos notables, y los más capaces son también los menos transparentes.

IA simbólica (*top-down*)

- ▶ **Idea:** la inteligencia surge de manipular símbolos con reglas lógicas.
- ▶ **Método:** representar el conocimiento explícitamente y aplicar un motor de inferencia.
- ▶ **Ejemplo:** SI fiebre > 38 Y tos = seca ENTONCES gripe
- + Transparente y auditable.
- Cuesta capturar el conocimiento; frágil ante lo no previsto.

IA conexionista (*bottom-up*)

- ▶ **Idea:** la inteligencia emerge de la interacción de muchas unidades simples.
- ▶ **Método:** aprender patrones y representaciones directamente de los datos.
- ▶ **Ejemplo:** redes neuronales profundas.
- + Escala con datos y cómputo; no requiere reglas.
- Opaca; depende de la calidad de los datos.

IA simbólica (*top-down*)


- ▶ **Idea:** la inteligencia surge de manipular símbolos con reglas lógicas.
- ▶ **Método:** representar el conocimiento explícitamente y aplicar un motor de inferencia.
- ▶ **Ejemplo:** SI fiebre > 38 Y tos = seca ENTONCES gripe
- + Transparente y auditable.
- Cuesta capturar el conocimiento; frágil ante lo no previsto.

IA conexionista (*bottom-up*)

- ▶ **Idea:** la inteligencia emerge de la interacción de muchas unidades simples.
- ▶ **Método:** aprender patrones y representaciones directamente de los datos.
- ▶ **Ejemplo:** redes neuronales profundas.
- + Escala con datos y cómputo; no requiere reglas.
- Opaca; depende de la calidad de los datos.

Hoy la frontera se difumina: los sistemas de producción combinan un modelo neuronal con estructuras simbólicas externas (llamadas a herramientas, bases de datos, verificadores, restricciones formales).

El ciclo del aprendizaje automático



- ▶ El programador ya no escribe la regla: escribe el **objetivo** (la función de pérdida) y deja que la optimización encuentre los parámetros.
- ▶ Todo el resto del curso son variaciones sobre este ciclo.

La misma idea, en tres líneas de matemática

Dado un conjunto de datos $\mathcal{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^n$ y una familia de funciones f_{θ} con parámetros θ :

$$\theta^* = \arg \min_{\theta} \underbrace{\frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(\mathbf{x}_i), \mathbf{y}_i)}_{\text{error en los datos}} + \underbrace{\lambda \Omega(\theta)}_{\text{regularización}}$$

La misma idea, en tres líneas de matemática

Dado un conjunto de datos $\mathcal{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^n$ y una familia de funciones f_{θ} con parámetros θ :

$$\theta^* = \arg \min_{\theta} \underbrace{\frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(\mathbf{x}_i), \mathbf{y}_i)}_{\text{error en los datos}} + \underbrace{\lambda \Omega(\theta)}_{\text{regularización}}$$

- ▶ ℓ es la **función de pérdida**: define qué significa equivocarse (clase 1.5).
- ▶ Ω penaliza soluciones complejas y controla el **sobreajuste** (clase 1.4).
- ▶ El arg min se resuelve por **descenso de gradiente** (clase 1.6).

La misma idea, en tres líneas de matemática

Dado un conjunto de datos $\mathcal{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^n$ y una familia de funciones f_θ con parámetros θ :

$$\theta^* = \arg \min_{\theta} \underbrace{\frac{1}{n} \sum_{i=1}^n \ell(f_\theta(\mathbf{x}_i), \mathbf{y}_i)}_{\text{error en los datos}} + \underbrace{\lambda \Omega(\theta)}_{\text{regularización}}$$

- ▶ ℓ es la **función de pérdida**: define qué significa equivocarse (clase 1.5).
- ▶ Ω penaliza soluciones complejas y controla el **sobreajuste** (clase 1.4).
- ▶ El $\arg \min$ se resuelve por **descenso de gradiente** (clase 1.6).
- ▶ Lo que interesa no es el error en $\mathcal{D}$, sino el error esperado en datos nuevos:

$\mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim P} [\ell(f_\theta(\mathbf{x}), \mathbf{y})]$ — el problema de la **generalización**.

Cuatro paradigmas de aprendizaje

Supervisado

Aprender de pares (entrada, **etiqueta**).

Diagnóstico a partir de imágenes médicas etiquetadas.

No supervisado

Encontrar estructura **sin** etiquetas.

Segmentar clientes por comportamiento de compra.

Auto-supervisado

La etiqueta se **extrae de los propios datos**: predecir la palabra siguiente, reconstruir una parte oculta.

Es lo que hace posible entrenar un LLM sobre texto no etiquetado.


Por refuerzo

Aprender por **ensayo y error** maximizando una recompensa.

Control, juegos y ajuste de modelos de lenguaje por preferencias.

Los sistemas actuales encadenan varios: pre-entrenamiento auto-supervisado → ajuste supervisado → refuerzo con retroalimentación.

El ecosistema de la IA



1. **La capacidad no se está estancando.** La industria produjo más del 90% de los modelos frontera de 2025, y varios superan la línea base humana en preguntas científicas de nivel doctoral y en matemática de competencia.

1. **La capacidad no se está estancando.** La industria produjo más del 90% de los modelos frontera de 2025, y varios superan la línea base humana en preguntas científicas de nivel doctoral y en matemática de competencia.
2. **La brecha EE.UU.–China se cerró.** Los mejores modelos de ambos países se han alternado el liderazgo desde 2025; en marzo de 2026 la diferencia es de 2,7%.

1. **La capacidad no se está estancando.** La industria produjo más del 90% de los modelos frontera de 2025, y varios superan la línea base humana en preguntas científicas de nivel doctoral y en matemática de competencia.
2. **La brecha EE.UU.–China se cerró.** Los mejores modelos de ambos países se han alternado el liderazgo desde 2025; en marzo de 2026 la diferencia es de 2,7%.
3. **La frontera es irregular (*jagged*).** Los mismos modelos que ganan medalla de oro en la Olimpiada Internacional de Matemática fallan al leer un reloj analógico.

1. **La capacidad no se está estancando.** La industria produjo más del 90% de los modelos frontera de 2025, y varios superan la línea base humana en preguntas científicas de nivel doctoral y en matemática de competencia.
2. **La brecha EE.UU.–China se cerró.** Los mejores modelos de ambos países se han alternado el liderazgo desde 2025; en marzo de 2026 la diferencia es de 2,7%.
3. **La frontera es irregular (*jagged*).** Los mismos modelos que ganan medalla de oro en la Olimpiada Internacional de Matemática fallan al leer un reloj analógico.
4. **La IA responsable no sigue el ritmo.** Los incidentes documentados subieron a **362** en 2025 (233 en 2024).

1. **La capacidad no se está estancando.** La industria produjo más del 90% de los modelos frontera de 2025, y varios superan la línea base humana en preguntas científicas de nivel doctoral y en matemática de competencia.
2. **La brecha EE.UU.–China se cerró.** Los mejores modelos de ambos países se han alternado el liderazgo desde 2025; en marzo de 2026 la diferencia es de 2,7%.
3. **La frontera es irregular (*jagged*).** Los mismos modelos que ganan medalla de oro en la Olimpiada Internacional de Matemática fallan al leer un reloj analógico.
4. **La IA responsable no sigue el ritmo.** Los incidentes documentados subieron a **362** en 2025 (233 en 2024).
5. **La adopción es históricamente rápida.** La IA generativa alcanzó $\approx 53\%$ de adopción poblacional en tres años; 88% de las organizaciones la usan.

AI Index 2026: seis conclusiones

1. **La capacidad no se está estancando.** La industria produjo más del 90% de los modelos frontera de 2025, y varios superan la línea base humana en preguntas científicas de nivel doctoral y en matemática de competencia.
2. **La brecha EE.UU.–China se cerró.** Los mejores modelos de ambos países se han alternado el liderazgo desde 2025; en marzo de 2026 la diferencia es de 2,7%.
3. **La frontera es irregular (*jagged*).** Los mismos modelos que ganan medalla de oro en la Olimpiada Internacional de Matemática fallan al leer un reloj analógico.
4. **La IA responsable no sigue el ritmo.** Los incidentes documentados subieron a **362** en 2025 (233 en 2024).
5. **La adopción es históricamente rápida.** La IA generativa alcanzó $\approx 53\%$ de adopción poblacional en tres años; 88% de las organizaciones la usan.
6. **La huella ambiental crece con las capacidades.** El entrenamiento de Grok 4 emitió 72.816 toneladas de CO₂ equivalente.

Fuente: *AI Index Report 2026*, Stanford HAI — *Top Takeaways*.

<https://hai.stanford.edu/ai-index/2026-ai-index-report>

Escala: parámetros de los modelos notables

Number of parameters of notable AI models by sector, 2003–25

Source: Epoch AI, 2026 | Chart: 2026 AI Index report




Figure 1.1.10

Lectura: El crecimiento en parámetros reportados se aplanan después de 2022, pero en gran medida porque los laboratorios frontera **dejaron de publicar** el dato. Ausencia de evidencia no es evidencia de ausencia.

Datos: tamaño del conjunto de entrenamiento

Training dataset size of notable AI models, 2010–25

Source: Epoch AI, 2026 | Chart: 2026 AI Index report



Figure 1.1.11

Lectura: Escala logarítmica: en quince años el corpus de entrenamiento pasó de 10^4 a más de 10^{13} tokens. El cuello de botella se desplaza desde el algoritmo hacia los datos.

Fuente: *AI Index Report 2026*, Stanford HAI — Figura 1.1.11.

Rendimiento frente a la línea base humana

Select AI Index technical performance benchmarks vs. human performance

Source: AI Index, 2026 | Chart: 2026 AI Index report




Figure 2.1.1¹


Lectura: Cada curva es un *benchmark* normalizado al 100 % humano. El patrón se repite: años de avance lento, luego saturación en pocos meses. Por eso los *benchmarks* caducan.

Fuente: *AI Index Report 2026*, Stanford HAI — Figura 2.1.1.

Comprensión del lenguaje: MMLU-Pro

MMLU-Pro: overall accuracy

Source: MMLU-Pro Leaderboard, 2026 | Chart: 2026 AI Index report



Lectura: Los quince mejores modelos se agrupan entre 87 % y 91 %: la prueba ya casi no discrimina. Cuando un *benchmark* se satura, deja de informar y hay que reemplazarlo.

- ▶ **MathArena** (problemas de competencia recién publicados): la exactitud subió de $\approx 83\%$ a **97%** entre noviembre y diciembre de 2025.

FrontierMath Tier 4: pass@1 accuracy

Source: Epoch AI, 2026 | Chart: 2026 AI Index report




Figure 2.5.4²⁴

Matemática: cuando el problema es realmente difícil

- ▶ **MathArena** (problemas de competencia recién publicados): la exactitud subió de $\approx 83\%$ a **97%** entre noviembre y diciembre de 2025.
- ▶ **FrontierMath Tier 4** (problemas originales que a un matemático profesional le toman horas o días): de casi 0% a **31,3%**.

FrontierMath Tier 4: pass@1 accuracy

Source: Epoch AI, 2026 | Chart: 2026 AI Index report




Figure 2.5.4²⁴

Matemática: cuando el problema es realmente difícil

- ▶ **MathArena** (problemas de competencia recién publicados): la exactitud subió de $\approx 83\%$ a **97%** entre noviembre y diciembre de 2025.
- ▶ **FrontierMath Tier 4** (problemas originales que a un matemático profesional le toman horas o días): de casi 0% a **31,3%**.
- ▶ Misma capacidad, dos lecturas opuestas según la dificultad del instrumento.

Implicación metodológica

Al leer un resultado, la primera pregunta no es *cuánto* sacó el modelo, sino **qué mide la prueba** y si sus ítems pudieron estar en el entrenamiento

FrontierMath Tier 4: pass@1 accuracy

Source: Epoch AI, 2026 | Chart: 2026 AI Index report




Figure 2.5.4²⁴

Razonamiento abstracto: ARC-AGI-2

ARC-AGI-2

Source: ARC-AGI-2 Leaderboard, 2026 | Chart: 2026 AI Index report




Figure 2.4.3¹⁶

Lectura: ARC-AGI-2 mide inferencia de reglas a partir de unos pocos ejemplos. El mejor modelo llega a 84,6 %, con una dispersión de casi 46 puntos entre modelos: la capacidad de *generalizar* varía mucho más que la de *recordar*.

La frontera irregular: leer un reloj

ClockBench: accuracy

Source: ClockBench Leaderboard, 2026 | Chart: 2026 AI Index report




Figure 2.4.8¹⁸

Lectura: El mejor modelo lee correctamente un reloj analógico el **50,6 %** de las veces, frente a $\approx 90 \%$ de las personas. La misma familia de modelos gana medalla de oro en la Olimpiada Internacional de Matemática.

SWE-bench: percent solved

Source: SWE-bench Leaderboard, 2026 | Chart: 2026 AI Index report





Figure 2.5.1¹¹

Lectura: SWE-bench evalúa la resolución de *issues* reales de GitHub. En un año el rendimiento pasó del 60 % al ≈ 100 % de la línea base humana. Terminal-Bench 2.0 subió de 20 % a 77,3 % en el mismo período.

Agentes: sistemas que ejecutan tareas de varios pasos

GAIA: accuracy

Source: GAIA Leaderboard, 2026 | Chart: 2026 AI Index report




- ▶ Un **agente** no responde: navega, llama herramientas, manipula archivos y encadena pasos hasta cumplir un objetivo.
- ▶ **GAIA**: de $\approx 20\%$ (enero 2025) a **74,5 %**, frente a 92 % humano.
- ▶ **OSWorld** (tareas reales de escritorio): de 12 % a $\approx 66\%$.

Agentes: sistemas que ejecutan tareas de varios pasos

GAIA: accuracy

Source: GAIA Leaderboard, 2026 | Chart: 2026 AI Index report



- ▶ Un **agente** no responde: navega, llama herramientas, manipula archivos y encadena pasos hasta cumplir un objetivo.
- ▶ **GAIA**: de $\approx 20\%$ (enero 2025) a **74,5 %**, frente a 92 % humano.
- ▶ **OSWorld** (tareas reales de escritorio): de 12 % a $\approx 66\%$.
- ▶ Pero aún fallan **1 de cada 3** intentos en pruebas estructuradas: suficiente para asistir, insuficiente para delegar sin supervisión.

Fuente: *AI Index Report 2026*, Stanford HAI — Figura 2.6.1.

Geopolítica del rendimiento: EE.UU. vs. China

Performance of top United States vs. Chinese models on the Arena

Source: Arena, 2026 | Chart: 2026 AI Index report




Figure 2.1.3³

Lectura: La ventaja estadounidense de 2023 prácticamente desapareció: 39 puntos Elo (2,7 %) en marzo de 2026. En inversión privada, en cambio, la asimetría persiste: 285,9 mil millones de dólares en EE.UU. frente a 12,4 mil millones en China.

Adopción: más rápida que el PC y que internet

Speed of AI adoption by technology

Source: The Project on Workforce at Harvard, 2025 | Chart: 2026 AI Index report




Figure 4.3.9^a

Lectura: Medido desde el primer producto masivo de cada tecnología, la IA generativa llegó al 53 % de la población en tres años. La adopción correlaciona fuertemente con el PIB per cápita.

Fuente: *AI Index Report 2026*, Stanford HAI — Figura 4.3.9.

Cuatro problemas que no son técnicos (solamente)

Sesgo

El modelo aprende los sesgos de sus datos y los aplica a escala.

Selección de personal, crédito, reconocimiento facial.

Transparencia y explicabilidad

¿Por qué el modelo decidió esto?

Crítico en medicina, finanzas y justicia; los modelos más capaces son los más opacos.

Privacidad

Los modelos pueden memorizar y filtrar datos sensibles del entrenamiento.

Riesgo agravado cuando se ajustan con datos internos.

Responsabilidad

¿Quién responde ante un daño: quien desarrolla, quien despliega o quien usa?

La respuesta es regulatoria, no algorítmica.

Los desarrolladores frontera reportan casi siempre métricas de capacidad, pero el reporte de *benchmarks* de IA responsable sigue siendo irregular.

Incidentes documentados

Number of reported AI incidents, 2012–25

Source: AI Incident Database (AIID), 2025 | Chart: 2026 AI Index report




Figure 3.2.1²

Lectura: 362 incidentes en 2025 frente a 233 en 2024. Parte del alza es mayor cobertura y mejor registro; aun así, la tendencia acompaña a la adopción, no a la madurez de las salvaguardas.

Fuente: *AI Index Report 2026*, Stanford HAI — Figura 3.2.1.

Huella ambiental del entrenamiento

Estimated carbon emissions from training select AI models and real-life activities, 2012–25

Source: AI Index, 2026; Strubell et al., 2019 | Chart: 2026 AI Index report




Figure 1.4.3

Lectura: De 0,01 toneladas de CO₂e (AlexNet, 2012) a **72.816** (Grok 4, 2025). Además, la capacidad eléctrica de los centros de datos de IA llegó a 29,6 GW, comparable al consumo peak del estado de Nueva York.

Producción de modelos

América Latina y el Caribe registran solo **2** modelos notables acumulados, frente a 666 de Europa y Asia Central. La región impulsa iniciativas propias como **Latam-GPT**.

Habilidades

Chile aparece, junto con Emiratos Árabes Unidos y Sudáfrica, entre los países con **crecimiento más rápido en habilidades de ingeniería de IA**, no solo de alfabetización digital.

Consecuencia para ustedes

La ventaja competitiva local no está en entrenar modelos frontera, sino en **adaptarlos y evaluarlos** sobre problemas y datos propios. Eso exige entender el ciclo completo: datos, pérdida, optimización y evaluación.

Fuente: *AI Index Report 2026*, Stanford HAI — Figura capítulos 1 y 7.

Concepto	Idea clave
IA	Agentes que perciben, razonan y actúan racionalmente
IA / ML / DL	Subconjuntos anidados; no toda la IA aprende de datos
Paradigmas	Símbolos (reglas) vs. conexiones (datos); hoy, híbridos
Ciclo de ML	Datos → pérdida → optimización → generalización
Estado del arte	Capacidad altísima pero irregular : la frontera es dentada
Evaluación	Los <i>benchmarks</i> se saturan; hay que leerlos con criterio
Riesgos	Sesgo, opacidad, privacidad, responsabilidad, energía

- ▶ La pregunta útil no es “¿la IA puede hacer X?”, sino “¿**bajo qué evaluación, con qué datos y con qué tasa de error?**”
- ▶ En la próxima clase abrimos la caja: sistemas expertos, el paradigma simbólico en detalle.

- ▶ Stanford HAI, *AI Index Report 2026*
<https://hai.stanford.edu/ai-index/2026-ai-index-report>
- ▶ Russell & Norvig, *Artificial Intelligence: A Modern Approach*, cap. 1–2.
- ▶ Prince, *Understanding Deep Learning* (libro abierto)
<https://udlbook.github.io/udlbook/>
- ▶ Zhang, Lipton, Li & Smola, *Dive into Deep Learning*
<https://d2l.ai/>
- ▶ Turing (1950), *Computing Machinery and Intelligence*, *Mind*.
- ▶ Bommasani et al. (2021), *On the Opportunities and Risks of Foundation Models*.

¿Preguntas?