

Redes Convolucionales

Convolución, pooling y arquitecturas clásicas

Sergio Hernández, PhD
shernandez@ucm.cl



Magíster en Data Science — Universidad Católica del Maule



¿Por qué no usar solo Redes Densas (FC) para Imágenes?

Explosión de Parámetros

Una red totalmente conectada trata una imagen como un vector plano.

- ▶ Una imagen de solo 100×100 píxeles a color (3 canales) tiene $100 \times 100 \times 3 = 30,000$ neuronas de entrada.
- ▶ Si la primera capa oculta tiene 1000 neuronas, ¡necesitaríamos $30,000 \times 1,000 = 30 \text{ millones}$ de pesos solo para esa capa.
- ▶ Esto es computacionalmente inviable y propenso al sobreajuste.

¿Por qué no usar solo Redes Densas (FC) para Imágenes?

Estructura Espacial

Al aplanar la imagen, se pierde la relación espacial entre píxeles vecinos.


- ▶ Un píxel en la esquina superior izquierda tiene la misma relación con su vecino que con un píxel en la esquina opuesta.
- ▶ La información visual es inherentemente **local**.

Los Principios Fundamentales de las CNNs

Las CNNs resuelven estos problemas basándose en dos ideas clave inspiradas en la visión humana:

1. Localidad (Locality)


Un píxel está fuertemente correlacionado con sus vecinos cercanos.



No necesitamos conectar cada píxel con todos los demás, solo con su vecindario local.

2. Invarianza a la Traslación

Un objeto sigue siendo el mismo objeto sin importar en qué parte de la imagen aparezca.




Capa Convolutiva

La convolución es una operación que extrae características locales de la imagen $g(\cdot)$ deslizando un pequeño filtro $f(\cdot)$ o **kernel** sobre ella.

$$(f * g)(i, j) = \sum_a \sum_b f(a, b)g(i - a, j - b). \quad (1)$$

imagen entrada

descriptores de salida



Convolución

7	8	9			
4	5	6	*		
1	2	3			


3	4
1	2

67	77
37	47

$$\begin{aligned}(7 \times 3) + (8 \times 4) + (4 \times 1) + (5 \times 2) &= 67, \\(8 \times 3) + (9 \times 4) + (5 \times 1) + (6 \times 2) &= 77, \\(4 \times 3) + (5 \times 4) + (1 \times 1) + (2 \times 2) &= 37, \\(5 \times 3) + (6 \times 4) + (2 \times 1) + (3 \times 2) &= 47.\end{aligned}$$

Padding (Relleno)

- ▶ Añade un borde de ceros alrededor de la imagen de entrada.
- ▶ Preserva las dimensiones espaciales (evitar que la imagen se encoja).
- ▶ Trata los píxeles de los bordes con la misma importancia que los centrales.




Padding

Stride (Paso)

Determina el número de píxeles que el kernel se desplaza en cada paso.

- ▶ Un stride > 1 reduce drásticamente el tamaño de la salida.
- ▶ Permite "saltar" información y tener un campo receptivo más amplio con menos cálculos.



Después de una capa de convolución (y una función de activación), es común aplicar una capa de Pooling.

Propósitos Principales:

1. **Reducir las dimensiones espaciales** (alto y ancho) del mapa de características.
2. **Reducir el costo computacional** y el número de parámetros en las capas siguientes.
3. Hacer que la representación sea más robusta a pequeñas **traslaciones** en la entrada.

Tipos Comunes:

- ▶ **Max Pooling:** Se toma el valor máximo de cada ventana. Es el más utilizado, ya que captura la característica más prominente.
- ▶ **Average Pooling:** Se toma el promedio de los valores de la ventana.

Sub-Muestreo (Pooling)

7	8	9
4	5	6
1	2	3

MAX Pooling (2×2)

8	9
5	6

$$\text{MAX}(7, 8, 4, 5) = 8,$$

$$\text{MAX}(8, 9, 5, 6) = 9,$$

$$\text{MAX}(4, 5, 1, 2) = 5,$$


$$\text{MAX}(5, 6, 2, 3) = 6,$$

Imágenes a color (3 canales de entrada):


- ▶ El kernel también debe tener 3 canales.
- ▶ La convolución se realiza canal por canal, y los resultados se suman para producir **un único mapa de características de salida**.

imagen entrada ($w \times h \times 3$)

kernel ($3 \times 3 \times 3$)




*



=




Red Neuronal Convolutional




LeNet-5

LeNet-5 (Yann LeCun, 1998) es una de las primeras CNNs exitosas, diseñada para el reconocimiento de dígitos manuscritos.




AlexNet (2012)

AlexNet (Krizhevsky et al., 2012) es red neuronal convolucional moderna implementada en GPU.




VGG16 (2014)

En VGG16 (Simonyan y Zisserman, 2014) los autores usan múltiples convoluciones y sub-samplio para construir bloques que pueden ser apilados en capas sucesivas.



ResNet (2016)

En ResNet (He et.al, 2016) los autores proponen normalización de lotes (BatchNorm) y bloques residuales (cortocircuito) del tipo $g(x) = f(x) + x$.



- ▶ Las CNNs son el estándar para tareas de visión por computadora porque respetan la **estructura espacial** de las imágenes.
- ▶ Sus bloques de construcción principales son:
 - ▶ **Capas Convolucionales:** Usan kernels (filtros) para aprender y detectar características locales.
 - ▶ **Capas de Pooling:** Reducen las dimensiones para hacer el modelo más eficiente y robusto.
- ▶ La arquitectura típica alterna estas capas de extracción de características y finaliza con capas densas para realizar la clasificación o regresión.
- ▶ Las CNNs no solo son potentes, sino también mucho más eficientes en parámetros que las redes densas gracias al **uso compartido de pesos**.