

Modelos Generativos

Autoencoders variacionales y modelos de flujo

Sergio Hernández, PhD
shernandez@ucm.cl



Magíster en Data Science — Universidad Católica del Maule

p_{θ}



- ▶ Una nueva generación de sistemas de IA capaces de crear contenido nuevo.
- ▶ Ejemplos:
 - ▶ Generación de texto (borradores, resúmenes).
 - ▶ Creación de imágenes artísticas.
 - ▶ Producción de videos realistas.



Prompt : Crea una imagen de un gato con un gorro de lana


modelos generativos

- ▶ Los modelos de clasificación mapean imágenes a etiquetas $f : \mathcal{X} \mapsto \mathcal{Y}$. Esta es una relación muchos a uno.
- ▶ Los modelos generativos mapean etiquetas a imágenes $g : \mathcal{Y} \mapsto \mathcal{X}$. Esta es una relación uno a muchos. Para manejar esta ambigüedad g es una función de probabilidad.




Redes Bayesianas (Kim & Pearl 1983, Pearl 1988)

- ▶ Utilizan un modelo gráfico (grafo) para representar una distribución conjunta entre variables aleatorias.
- ▶ Induce una relación de independencia condicional $p(a, b, c) = p(c|a, b)p(b|a)p(a)$



Redes Bayesianas (Kim & Pearl 1983, Pearl 1988)

- ▶ Utilizan un modelo gráfico (grafo) para representar una distribución conjunta entre variables aleatorias.
- ▶ Induce una relación de independencia condicional $p(a, b, c) = p(c|a, b)p(b|a)p(a)$




- ▶ Las Redes Bayesianas permiten calcular la probabilidad de un evento dada la evidencia.
- ▶ Son ampliamente usadas en modelos causales y en entornos donde se requiere explicar las predicciones (diagnóstico médico, sistema de apoyo a las decisiones, visión computacional).

Teorema de Bayes


$$\underbrace{\text{posterior}}_{P(B|A)} = \frac{\underbrace{\text{verosimilitud}}_{P(A|B)} \times \underbrace{\text{prior}}_{P(B)}}{\underbrace{\text{evidencia}}_{P(A)}}$$

$$z \in \{\text{Feliz, Enojado}\}$$
$$p(z|x) = \frac{p(x|z) \times p(z)}{p(x)}$$



Inferencia Bayesiana

- ▶ La tarea básica del método de inferencia probabilístico es calcular la distribución posterior para un nodo dado que se conoce el valor de un conjunto de nodos que aportan evidencia.
- ▶ En el caso de la estructuras de grafos en serie (cadenas), el proceso de inferencia requiere aplicar de manera repetida el teorema de Bayes.




El cielo es

azul

$$p_{\theta}(x) = \prod_{i=1}^N p_{\theta}(x_i | x_{<i}) \quad (1)$$


VAE (Kingma & Welling, 2011)

- ▶ Los Autoencoders utilizan una variable latente z y una distribución marginal $p(x) = \int p_\theta(x|z)p(z)dz$
- ▶ El modelo generativo utiliza una distribución apriori $z \sim p(z)$ y luego genera muestras de acuerdo a $x \sim p(x)$
- ▶ Dado que obtener muestras directamente desde $p(x)$ es intratable, el modelo VAE utiliza una cota inferior de la verosimilitud $q_\theta(z|x)$.



Flujo Normalizador (Rezende & Mohamed, 2015)

- ▶ Es un modelo que utiliza redes neuronales para aprender distribuciones complejas a partir de transformaciones de distribuciones mas simples.
- ▶ Permiten obtener muestras de distribuciones complejas y a la vez evaluar la probabilidad de observar nuevos ejemplos.
- ▶ Se basa en el terorema de cambio de variables a partir de transformaciones invertibles ϕ^{-1}



Conservación de Masa


$$\int_{\mathcal{X}} p(x) dx = \int_{\mathcal{Z}} p(z) dz = 1$$

$$p(z) = p(x) \left| \det \left(\frac{\partial \phi(x)}{\partial x} \right) \right|^{-1}$$

$$\phi(x) = \log(x - a)$$

$$\phi^{-1}(z) = \exp(z) + a$$

$$\begin{aligned} p(z) &= p(x) \left| \det \left(\frac{\partial \phi(x)}{\partial x} \right) \right|^{-1} \\ &= p(x) \exp(z) \end{aligned}$$



- ▶ Inicia generando una variable aleatoria $z_0 \sim \mathcal{N}(0, I,)$
- ▶ Realiza k transformaciones biyectivas de manera sucesiva ϕ_k
- ▶ Genera muestras $x = z_k$ al final de la cadena

$$x = \phi_k \circ \phi_{k-1} \circ \dots \circ \phi_1(z_0) \tag{2}$$