Segmentación Semántica Profunda

Arquitecturas, funciones objetivo, métricas y aplicaciones en oftalmología

Sergio Hernández, PhD
shernandez@ucm.cl



Magíster en Data Science — Universidad Católica del Maule

Segmentación Semántica vs. Clasificación

Clasificación

- Una etiqueta para **la imagen completa**.
- Respuesta: *que es esto?*
- Salida: clase global, probabilidades.

Segmentación Semántica

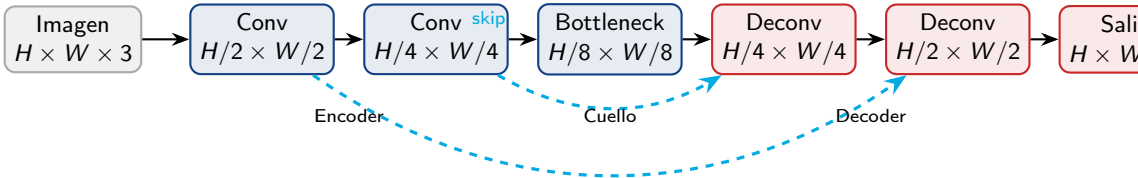
- Una etiqueta para **cada pixel**.
- Respuesta: *que es cada parte*.
- Salida: mapa de etiquetas (altura $\times$ ancho).

Aplicación Clave en Medicina

Localizar y cuantificar estructuras anatómicas o lesiones: tumores, vasos sanguíneos, retina.

Flujo Básico: Encoder-Decoder

La mayoría de arquitecturas modernas siguen este patron:



Componentes

- **Encoder:** extrae características a multiples escalas.
- **Bottleneck:** representación comprimida profunda.
- **Decoder:** reconstruye la resolución espacial.
- **Skip connections:** preservan detalles locales.

U-Net: Arquitectura Fundamental

La arquitectura **U-Net** (Ronneberger et al., 2015) fue disenada para segmentación medica.

Encoder: $H \to H/2 \to H/4 \to \cdots$ Decoder: $\cdots \to H/4 \to H/2 \to H$

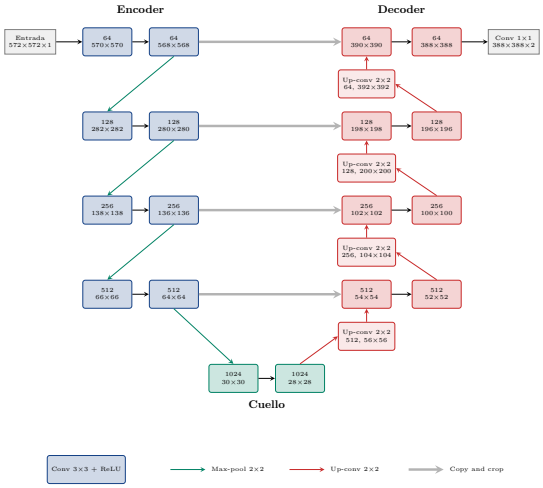
Ventajas

- Pocos parámetros (muy eficiente).
- Skip connections garantizan detalles.
- Excelente para datos pequenos.

Desventajas

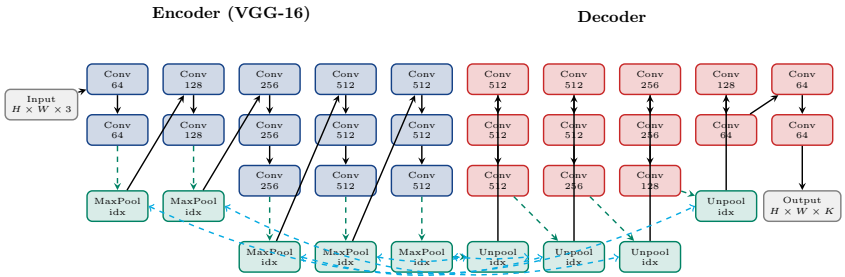
- Receptive field limitado.
- Sin contexto global explícito.
- Requiere mas datos para escenas complejas.

U-Net: Diagrama de la Arquitectura



SegNet: Pooling con Índices

SegNet (Badrinarayanan et al., 2017) almacena solo los índices del max-pooling en el encoder y los reutiliza para el unpooling en el decoder.



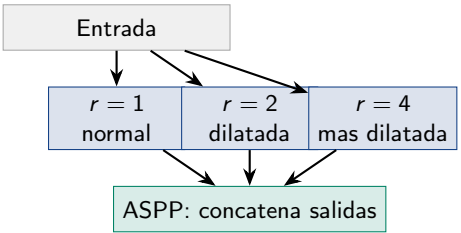
Key Feature: Max-pooling indices stored in encoder, reused in decoder

This preserves spatial structure while reducing parameters vs. U-Net

DeepLab: Contexto Global con Atrous Convolutions

DeepLab introduce convolución atrous (dilatada) para capturar contexto multi-escala:

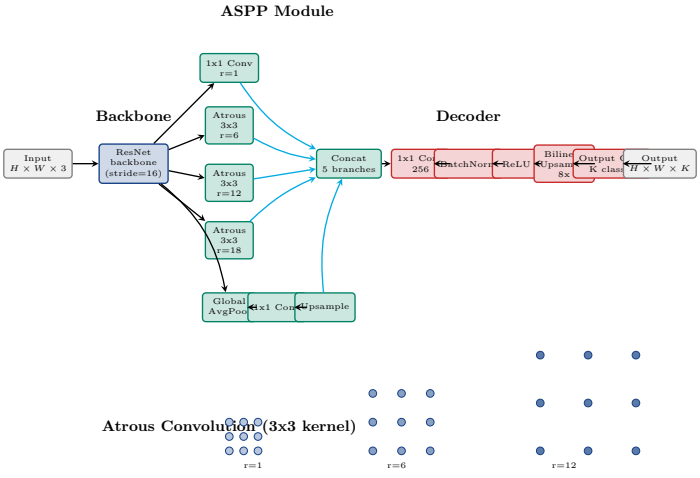
$$y[i] = \sum_k x[i + r \cdot k] \cdot w[k], \quad r = \text{tasa de dilatación}$$



Ventaja Clave

Mayor receptive field sin reducir resolución. Detalles + contexto global.

DeepLab: Módulo ASPP



Dice Loss: Optimizar Solapamiento

El **coeficiente Dice** es una metrica que tambien funciona como perdida:

$$\text{Dice}(y, \hat{y}) = \frac{2|y \cap \hat{y}|}{|y| + |\hat{y}|}, \qquad \mathcal{L}_{\text{Dice}} = 1 - \text{Dice}$$

Ventajas sobre Cross-Entropy

- Directamente optimiza IoU (metrica final).
- Menos sensible a desbalance de clases.
- Enfatiza objetos pequenos.

Estrategia Practica

Combina CE + Dice. Agrega boundary loss si los bordes son criticos.

Metricas Pixel-Level

Dice (F1-Score)

$$\text{Dice} = \frac{2\text{TP}}{2\text{TP} + \text{FP} + \text{FN}}$$

Robusto a desbalance de clases.

IoU (Jaccard)

$$\text{IoU} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}}$$

Intersección sobre unión.

Sensibilidad (Recall)

$$\text{Sens} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Proporción de positivos detectados.

Especificidad

$$\text{Spec} = \frac{\text{TN}}{\text{TN} + \text{FP}}$$

Tasa de negativos correctos.

Recomendacion

Reporta **siempre** Dice e IoU, mas sensibilidad y especificidad.

Retinopatía Diabetica

La **retinopatía diabética (DR)** es la principal causa de ceguera en adultos desarrollados.

Signos Tempranos

- Microaneurismas.
- Hemorragias retinianas.
- Exudados duros (lipidos).
- Edema macular diabetico.

Desafio

- Lesiones pequenas y dispersas.
- Variabilidad entre pacientes.
- Requiere expertos oftalmologos.
- Screening de poblaciones masivas.

Oportunidad

Automatizar screening, cuantificar lesiones, predecir progresion.

Segmentacion de Vasos Sanguineos

Extraer la **red vascular retiniana** de imagenes de fundus.

Arquitectura tipica

U-Net o SegNet. Entrada: $512 \times 512 \times 3$. Salida: $512 \times 512 \times 1$ (vaso/no-vaso).

Desafios

- Vasos muy finos (1-2 pixeles).
- Bajo contraste en areas oscuras.
- Precision en bordes.

Metricas clave

Dice ≥ 0.8, Sensibilidad ≥ 0.75.

Desafios en Oftalmologia

Datos Limitados

Datasets pequenos, anotacion costosa, imbalance de clases.
Solucion: Transfer learning, augmentation.

Calidad de Imagen

Ruido, bajo contraste, cataratas, desalineamiento.
Solucion: Preprocessing (CLAHE).

Interpretabilidad

Clinicos necesitan explicacion del modelo.
Solucion: Grad-CAM, attention maps.

Conclusiones

- **Segmentacion profunda:** base para diagnostico medico automatizado.
- **Arquitecturas:** U-Net (datos pequenos), DeepLab (contexto global).
- **Funciones objetivo:** combinar Dice + Cross-Entropy.
- **Metricas:** Dice, IoU, sensibilidad, especificidad.
- **Oftalmologia:** vasos, lesiones, disco/cupula. Cada tarea con matices propios.
- **Desafios:** datos limitados, variabilidad de camaras, interpretabilidad.